Анализ данных (Введение в Python и обработку таблиц)

Логинов Сергей НФИмд-01-22

Сылка на курс: https://stepik.org/course/126333?search=1440407514

Образовательная организация: ТюмГУ

Трудоемкость: 7 часов

В данном курсе не выдается сертификат от платформы, но имеется возможность получить удостоверение от Тюменского государственного университета. Информация по теме из курса:

Уважаемые слушатели курса!

Вы можете бесплатно получить **удостоверение государственного образца о повышении квалификации** по курсу «Анализ данных» от Тюменского государственного университета!

Пройдите регистрацию до 1 декабря 2022 года, и получите удостоверение уже в этом году.

Ссылка на регистрацию

Вам понадобятся документы:

- паспорт;
- снилс;
- документ об образовании;
- подписанное вами согласие на обработку персональных данных (форма Согласия на обработку ПД)

Сохранено

разработки Google Colab. Она похожа на jupyter, но использует облачные вычисления, а значит не требует установки каких-либо программ или пакетов и не ест ресурсы комьютера. Есть интеграция с Google диском, что тоже удобно.

Основы обработки таблиц с данными на языке Python

```
import pandas as pd

df = pd.read_csv('/content/drive/MyDrive/Colab Notebooks/students.csv',
                 delimiter=',')
```

Повторим вычисление статистических характеристик.

Для начала некоторые функции суммарной статистики по всему датасету

```
df.head()
```

	Age	Growth	Shoe size	Course number	Year of birth	Friend number	Russian rating	Maths rating	Physics rating	Compute scienc ratir
0	20	170	40	2	2002	100	85	86	0	8
1	22	191	43	7	2000	307	69	74	64	7
2	21	172	41	4	2000	186	78	62	0	
3	19	168	38	2	2003	604	72	0	0	
4	23	159	36	1	1998	144	0	0	0	

5 rows × 48 columns

```
df.describe()
```

	Age	Growth	Shoe size	Course number	Year of birth	Friend number	F
count	186.000000	186.000000	186.000000	186.000000	186.000000	186.000000	186
mean	20.688172	170.661290	39.715054	3.500000	1991.107527	374.032258	81
std	3.468713	9.055881	2.814920	3.147285	132.099550	2199.541507	14
min	17.000000	153.000000	34.000000	0.000000	200.000000	0.000000	0
25%	19.000000	164.000000	38.000000	2.000000	2000.000000	74.500000	76
50%	20.000000	169.000000	39.000000	3.000000	2001.500000	130.000000	85
75%	21.000000	178.000000	42.000000	4.000000	2003.000000	236.000000	91
max	55.000000	197.000000	48.000000	37.000000	2004.000000	30000.000000	100

8 rows × 33 columns

```
# df.value_counts() - вычисляет значения, но выглядит громоздко,
# просто закомментируем и запомним

df['Growth'].mean() # средний рост = математическое ожидание
```

```
170.66129032258064
```

```
df['Growth'].median() # медиана
```

```
169.0
```

```
df.Growth.std() # СКО
```

```
9.055880959226972
```

Далее в курсе проводится введение в фильтрацию/селекцию данных в датасете, получение слайсов и т.д. Тема простая и заранее изученная, идет как базовая, поэтому считаю, что не обязательно полностью отражать ее в отчете. Однако, для повторения или если встретятся спорные или неизвестные моменты, они будут зафиксированы ниже

```
# базовая селекция как образец
df[df.Sex == 'женский'].head()
```

	Age	Growth	Shoe size	Course number	Year of birth	Friend number	Russian rating	Maths rating	Physics rating	Comput scien rati
0	20	170	40	2	2002	100	85	86	0	
3	19	168	38	2	2003	604	72	0	0	
4	23	159	36	1	1998	144	0	0	0	
9	22	168	38	6	2000	297	71	5	0	
10	20	158	35	4	2001	1000	85	72	0	

5 rows × 48 columns

```
df[(df.Growth > 165) & (df.Growth < 175)].head() # двойная
```

	Age	Growth	Shoe size	Course number	Year of birth	Friend number	Russian rating	Maths rating	Physics rating	Comput scien rati
0	20	170	40	2	2002	100	85	86	0	
2	21	172	41	4	2000	186	78	62	0	
3	19	168	38	2	2003	604	72	0	0	
9	22	168	38	6	2000	297	71	5	0	
12	21	169	39	4	2001	150	68	27	0	

5 rows × 48 columns

```
df[df.Age + df['Year of birth'] == 2022].shape # колиечство людей,
# которые отпраздновали
# день рождения в этом году
```

```
(102, 48)
```

```
df[df.Age == df.Age.max()]
```

	Age	Growth	Shoe size	Course number	Year of birth	Friend number	Russian rating	Maths rating	Physics rating	Comput scien rati
81	55	160	37	7	1960	2000	0	0	0	

1 rows × 48 columns

Влияние строк и столбцов друг на друга

Группировка, сортировка и корреляция

```
df_cut = df[['Age', 'Growth', 'Weight']]
df_cut.head()
```

	Age	Growth	Weight
0	20	170	64.0
1	22	191	73.0
2	21	172	60.0
3	19	168	59.0
4	23	159	57.0

Сортировка

```
df_cut.sort_values(by='Age', ascending=False)
```

	Age	Growth	Weight
81	55	160	3.0
63	35	180	78.0
99	31	165	53.0
173	29	176	70.0
82	27	168	58.0
...	...	...	...
127	18	165	46.0
61	18	182	75.0
159	18	168	70.0
115	17	175	72.0
126	17	168	71.0

186 rows × 3 columns

```
# множественная сортировка
df_cut.sort_values(by=['Age', 'Growth'], ascending=[False, True])
```

	Age	Growth	Weight
81	55	160	3.0
63	35	180	78.0
99	31	165	53.0
173	29	176	70.0
82	27	168	58.0
...	...	...	...
112	18	183	65.0
16	18	185	64.0
42	18	185	68.0
126	17	168	71.0
115	17	175	72.0

186 rows × 3 columns

```
df_sorted = df_cut.sort_values(by='Growth', ascending=False)
```

Обращение по индексам и слайсы

```
df_sorted.iloc[0,]
```

```
Age        19.0
Growth    197.0
Weight    100.0
Name: 103, dtype: float64
```

Добавление столбцов в датасет

```
df_cut['BMI'] = 10000 * df_cut['Weight'] / (df_cut['Growth'] * df_cut['Growth'])
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: SettingWith
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs
  """Entry point for launching an IPython kernel.
```

```
df_cut.head()
```

	Age	Growth	Weight	BMI
0	20	170	64.0	22.145329
1	22	191	73.0	20.010416
2	21	172	60.0	20.281233
3	19	168	59.0	20.904195
4	23	159	57.0	22.546576

Коэффициент корреляции

```
df_cut.corr()
```

	Age	Growth	Weight	BMI
Age	1.000000	-0.101982	-0.185722	-0.200305
Growth	-0.101982	1.000000	0.544528	0.146201
Weight	-0.185722	0.544528	1.000000	0.904678
BMI	-0.200305	0.146201	0.904678	1.000000

Группировка

```
df.groupby('Sex')['Growth', 'Weight'].mean()
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: FutureWarni
  """Entry point for launching an IPython kernel.
```

Sex	Growth	Weight
женский	165.725000	59.105263
мужской	179.636364	71.580645

```
df.groupby(['Sex', 'Chocolate'])['Russian rating', 'Maths rating'].mean()
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: FutureWarni
  """Entry point for launching an IPython kernel.
```

		Russian rating	Maths rating
Sex	**Chocolate**		
женский	**M&Ms**	79.400000	51.600000
	Баунти	81.181818	56.318182
	КитКат	85.782609	61.782609
	Марс	91.166667	36.666667
	Милки Вей	79.583333	45.250000
	Натс	84.636364	53.818182
	Скиттлс (хотя это и не шоколадка)	86.000000	67.000000
	Сникерс	80.375000	61.562500
	Твикс	86.478261	55.217391
мужской	**M&Ms**	83.666667	76.666667
	Баунти	78.375000	68.000000
	КитКат	74.416667	51.083333
	Марс	85.600000	55.400000
	Милки Вей	72.800000	61.800000
	Натс	70.500000	72.000000
	Скиттлс (хотя это и не шоколадка)	84.000000	77.000000
	Сникерс	77.666667	59.055556
	Твикс	79.818182	75.000000

Базовые операции с данными

Визуализация данных

```
import seaborn as sns
```

```
# гистограмма распределения
sns.displot(data=df, x='Growth')
```

```
<seaborn.axisgrid.FacetGrid at 0x7f9acb806c10>
```

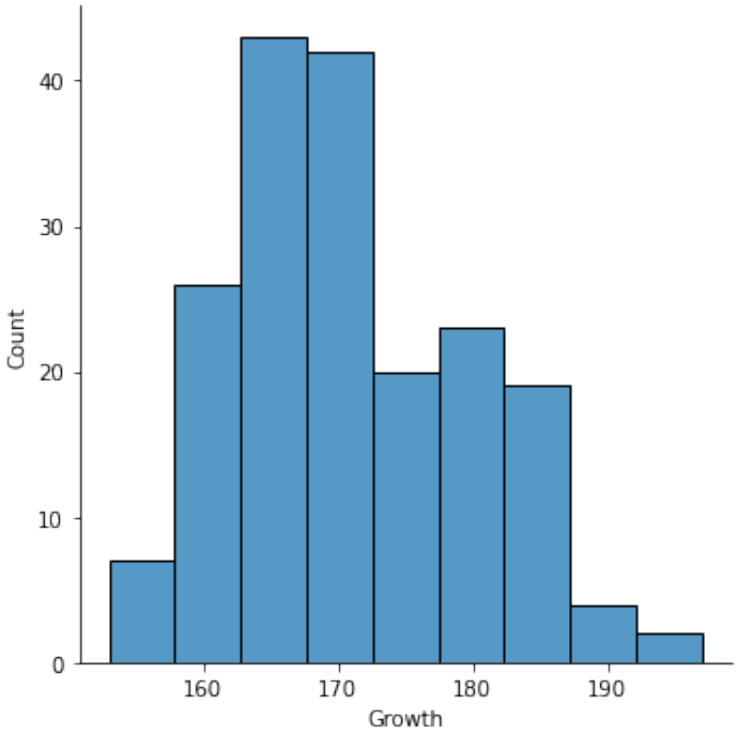


```
sns.displot(data=df, x='Growth', kind='kde')
```

```
<seaborn.axisgrid.FacetGrid at 0x7f9acb162b90>
```

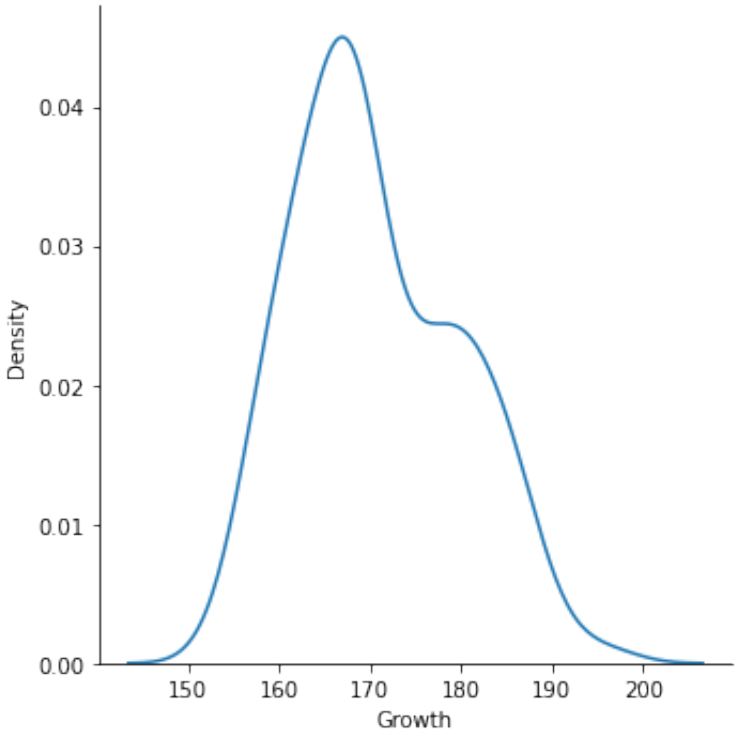

```
# точечный график
sns.scatterplot(data=df, x='Growth', y='Weight')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac7b45810>
```

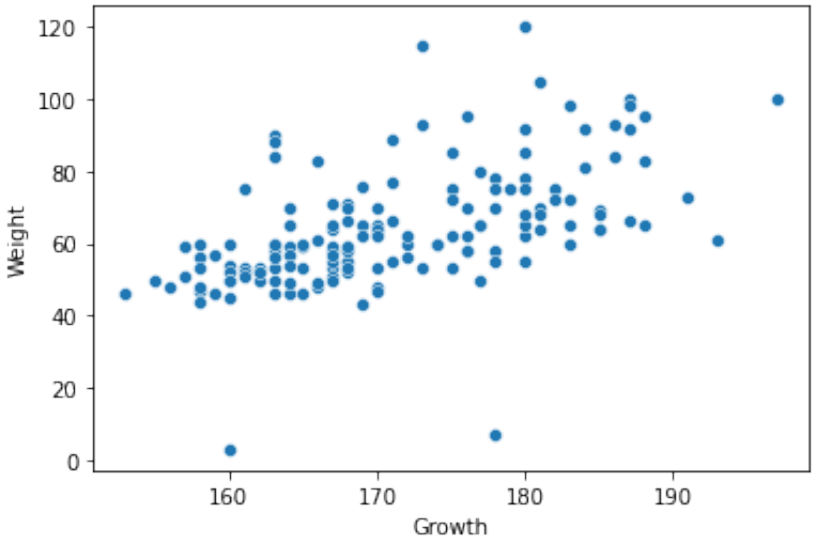


```
sns.scatterplot(data=df, x='Growth', y='Weight', hue='Sex')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac7ac0110>
```

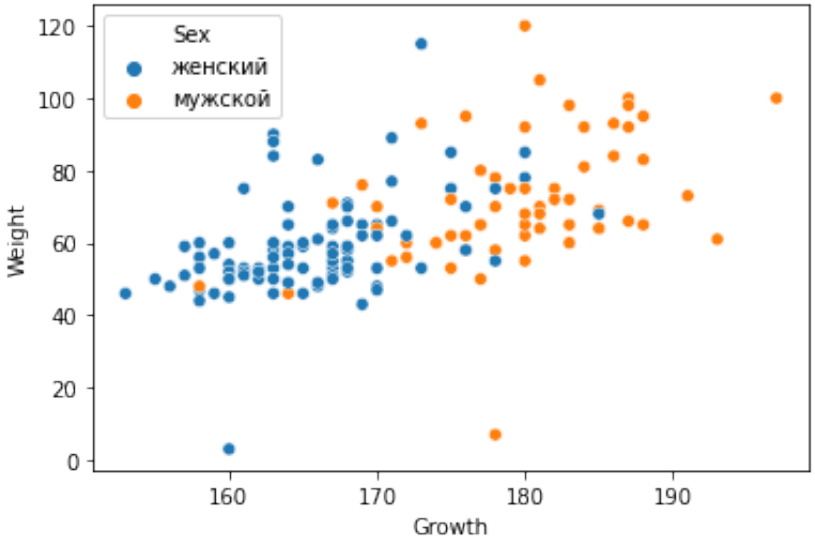

Визуализация категориальных признаков

```
sns.countplot(x=df['Sex']) # or data=df, x='Sex'
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac7b378d0>
```

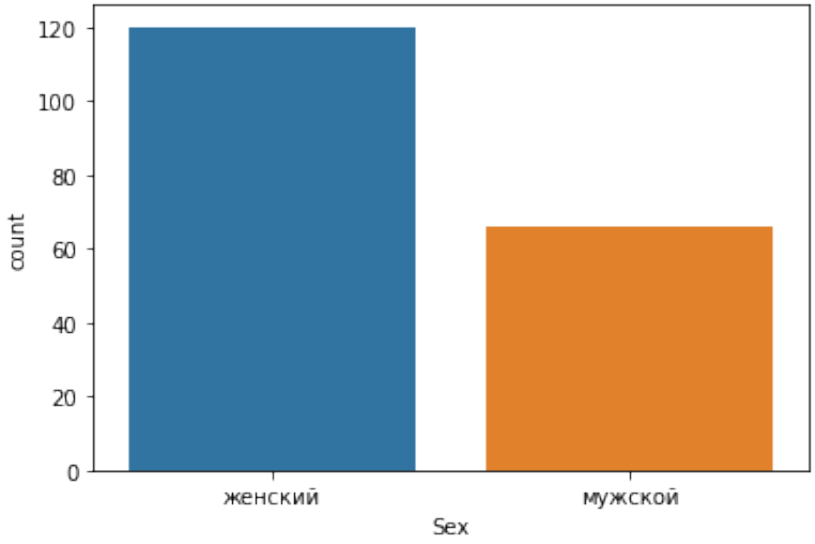


```
sns.countplot(data=df, x='Sex', hue='Animal')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac7999890>
```

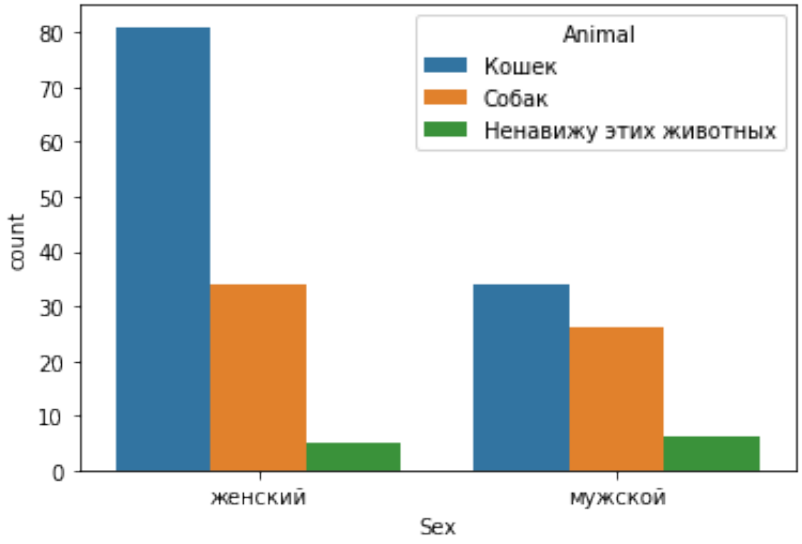

Построение нескольких графиков

```
df_cut['Shoe_size'] = df['Shoe size']
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: SettingWith
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs
  """Entry point for launching an IPython kernel.
```

```
sns.pairplot(df_cut)
```

```
<seaborn.axisgrid.PairGrid at 0x7f9ac79176d0>
```

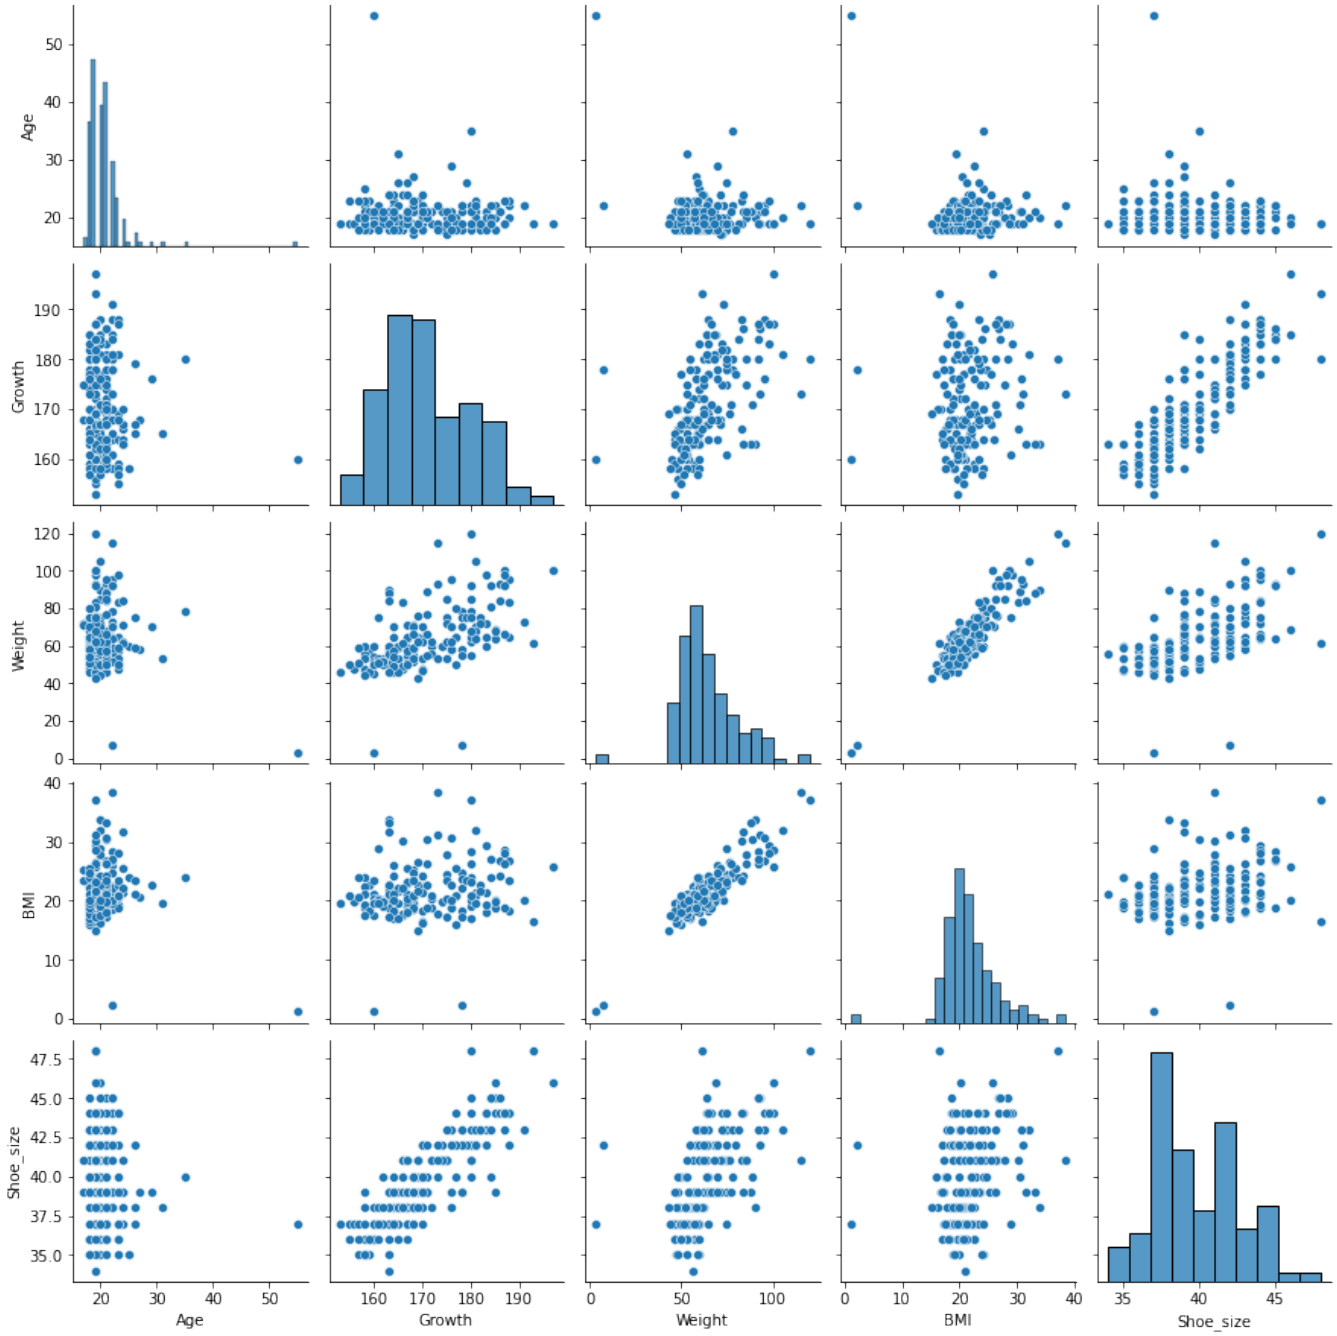

Здесь по диагонали находится гистограмма признака, а в остальных ячейках - парные точечные диаграммы

```
df_cut['Sex'] = df.Sex
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: SettingWith
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs
  """Entry point for launching an IPython kernel.
```

```
sns.pairplot(df_cut, hue='Sex')
```

```
<seaborn.axisgrid.PairGrid at 0x7f9ac6fcedd0>
```

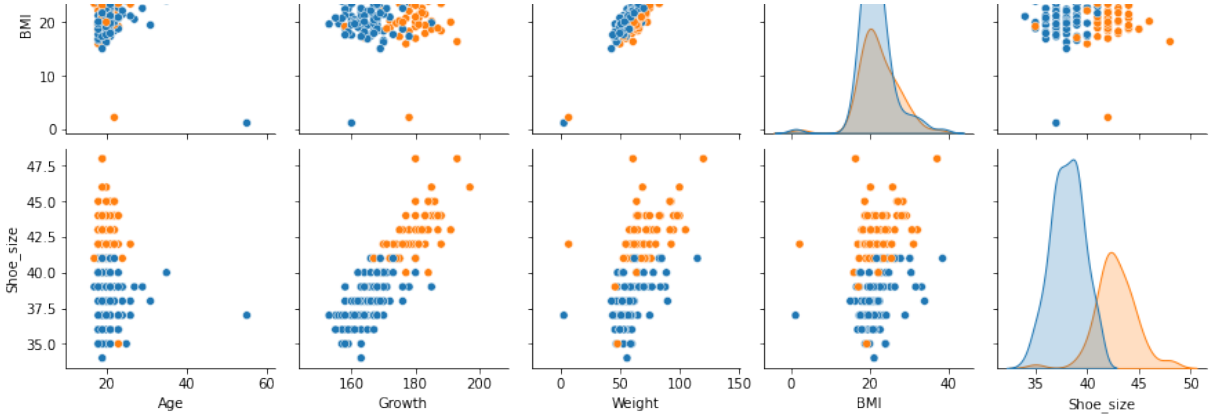

Работа с пропусками в данных и отсутствующими значениями

```
# Простое удаление пропусков
df1 = df.dropna()
df1.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 118 entries, 0 to 185
Data columns (total 48 columns):
 #   Column                      Non-Null Count  Dtype
---  ------                      --------------  -----
 0   Age                         118 non-null    int64
 1   Growth                      118 non-null    int64
 2   Shoe size                   118 non-null    int64
 3   Course number               118 non-null    int64
 4   Year of birth               118 non-null    int64
 5   Friend number               118 non-null    int64
 6   Russian rating              118 non-null    int64
 7   Maths rating                118 non-null    int64
 8   Physics rating              118 non-null    int64
 9   Computer science rating     118 non-null    int64
```

```
 9   Computer science rating      118 non-null    int64
 10  Chemistry rating             118 non-null    int64
 11  Literature rating            118 non-null    int64
 12  History rating               118 non-null    int64
 13  Geography rating             118 non-null    int64
 14  Biology rating               118 non-null    int64
 15  Foreign language rating      118 non-null    int64
 16  Social science rating        118 non-null    int64
 17  Distance to home km          118 non-null    int64
 18  Minutes to first class       118 non-null    int64
 19  Children number              118 non-null    float64
 20  Removed teeth                118 non-null    float64
 21  Weight                       118 non-null    float64
 22  Glasses                      118 non-null    object
 23  Sex                          118 non-null    object
 24  Problems in last semester    118 non-null    object
 25  Coin                         118 non-null    object
 26  Rock paper scissors          118 non-null    object
 27  Animal                       118 non-null    object
 28  Month of birthday            118 non-null    int64
 29  Your rating in university    118 non-null    object
 30  Fastfood                     118 non-null    object
 31  Height of 5000 mm            118 non-null    int64
 32  Width of 5000 mm             118 non-null    int64
 33  Putin age                    118 non-null    int64
 34  Army                         118 non-null    object
 35  Hostel                       118 non-null    object
 36  Hair length                  118 non-null    float64
 37  Floor number                 118 non-null    int64
 38  Social network duration min  118 non-null    int64
 39  Chocolate                    118 non-null    object
 40  City population              118 non-null    float64
 41  Strange people               118 non-null    object
 42  Your insitute                118 non-null    object
 43  Brother-sister               118 non-null    object
 44  Plane seat                   118 non-null    object
 45  MIddle and index finger      118 non-null    int64
 46  Middle and ring finger       118 non-null    float64
 47  Middle and little finger     118 non-null    float64
dtypes: float64(7), int64(26), object(15)
memory usage: 45.2+ KB
```

Удалили много теоретически полезной информации, лучше воспользоваться заменой пропусков

```
df.isnull().sum()
```

```
Age                              0
Growth                           0
Shoe size                        0
Course number                    0
Year of birth                    0
Friend number                    0
Russian rating                   0
Maths rating                     0
Physics rating                   0
Computer science rating          0
Chemistry rating                 0
Literature rating                0
History rating                   0
Geography rating                 0
Biology rating                   0
Foreign language rating          0
Social science rating            0
Distance to home km              0
Minutes to first class           0
Children number                 36
Removed teeth                   38
Weight                          29
Glasses                          2
Sex                              0
Problems in last semester        0
Coin                             0
Rock paper scissors              0
Animal                           0
Month of birthday                0
Your rating in university        0
Fastfood                         0
Height of 5000 mm                0
Width of 5000 mm                 0
Putin age                        0
Army                             0
Hostel                           0
Hair length                      0
Floor number                     0
Social network duration min      0
Chocolate                        0
City population                  0
Strange people                   0
Your insitute                    0
Brother-sister                   0
Plane seat                       0
MIddle and index finger          0
Middle and ring finger           0
Middle and little finger         0
dtype: int64
```

```
df2 = df.fillna(0)
df2.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 186 entries, 0 to 185
Data columns (total 48 columns):
 #   Column                        Non-Null Count  Dtype  
---  ------                        --------------  -----  
 0   Age                           186 non-null    int64  
 1   Growth                        186 non-null    int64  
 2   Shoe size                     186 non-null    int64  
 3   Course number                 186 non-null    int64  
 4   Year of birth                 186 non-null    int64  
 5   Friend number                 186 non-null    int64  
 6   Russian rating                186 non-null    int64  
 7   Maths rating                  186 non-null    int64  
 8   Physics rating                186 non-null    int64  
 9   Computer science rating       186 non-null    int64  
 10  Chemistry rating              186 non-null    int64  
 11  Literature rating             186 non-null    int64  
 12  History rating                186 non-null    int64  
 13  Geography rating              186 non-null    int64  
 14  Biology rating                186 non-null    int64  
 15  Foreign language rating       186 non-null    int64  
 16  Social science rating         186 non-null    int64  
 17  Distance to home km           186 non-null    int64  
 18  Minutes to first class        186 non-null    int64  
 19  Children number               186 non-null    float64
 20  Removed teeth                 186 non-null    float64
 21  Weight                        186 non-null    float64
 22  Glasses                       186 non-null    object 
 23  Sex                           186 non-null    object 
 24  Problems in last semester     186 non-null    object 
 25  Coin                          186 non-null    object 
 26  Rock paper scissors           186 non-null    object 
 27  Animal                        186 non-null    object 
 28  Month of birthday             186 non-null    int64  
 29  Your rating in university     186 non-null    object 
 30  Fastfood                      186 non-null    object 
 31  Height of 5000 mm             186 non-null    int64  
 32  Width of 5000 mm              186 non-null    int64  
 33  Putin age                     186 non-null    int64  
 34  Army                          186 non-null    object 
 35  Hostel                        186 non-null    object 
 36  Hair length                   186 non-null    float64
 37  Floor number                  186 non-null    int64  
 38  Social network duration min   186 non-null    int64  
 39  Chocolate                     186 non-null    object 
 40  City population               186 non-null    float64
 41  Strange people                186 non-null    object 
 42  Your insitute                 186 non-null    object 
 43  Brother-sister                186 non-null    object 
 44  Plane seat                    186 non-null    object 
 45  MIddle and index finger       186 non-null    int64  
```

```
 46  Middle and ring finger       186 non-null    float64
 47  Middle and little finger     186 non-null    float64
dtypes: float64(7), int64(26), object(15)
memory usage: 69.9+ KB
```

Можно также заменить на медиану/среднее значение и тд

```
df2.isnull().sum()
```

```
Age                            0
Growth                         0
Shoe size                      0
Course number                  0
Year of birth                  0
Friend number                  0
Russian rating                 0
Maths rating                   0
Physics rating                 0
Computer science rating        0
Chemistry rating               0
Literature rating              0
History rating                 0
Geography rating               0
Biology rating                 0
Foreign language rating        0
Social science rating          0
Distance to home km            0
Minutes to first class         0
Children number                0
Removed teeth                  0
Weight                         0
Glasses                        0
Sex                            0
Problems in last semester      0
Coin                           0
Rock paper scissors            0
Animal                         0
Month of birthday              0
Your rating in university      0
Fastfood                       0
Height of 5000 mm              0
Width of 5000 mm               0
Putin age                      0
Army                           0
Hostel                         0
Hair length                    0
Floor number                   0
Social network duration min    0
Chocolate                      0
City population                0
Strange people                 0
Your insitute                  0
Brother-sister                 0
Plane seat                     0
MIddle and index finger        0
Middle and ring finger         0
Middle and little finger       0
dtype: int64
```

Замена по столбцу

```
df['Weight'].fillna(df['Weight'].mean())
```

```
0      64.0
1      73.0
2      60.0
3      59.0
4      57.0
       ...
181    59.0
182    43.0
183    51.0
184    62.0
185    54.0
Name: Weight, Length: 186, dtype: float64
```

Замена пропусков в категориальных признаках

```
df['Glasses'] = df['Glasses'].fillna('да')
```

Выбросы и аномалии

Очень часто их можно найти при парном анализе двух признаков

Можно проверить с помощью визуализации (box plot)

```
sns.boxplot(df['Age'])
```

```
/usr/local/lib/python3.7/dist-packages/seaborn/_decorators.py:43: FutureWar
  FutureWarning
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac4a8d510>
```

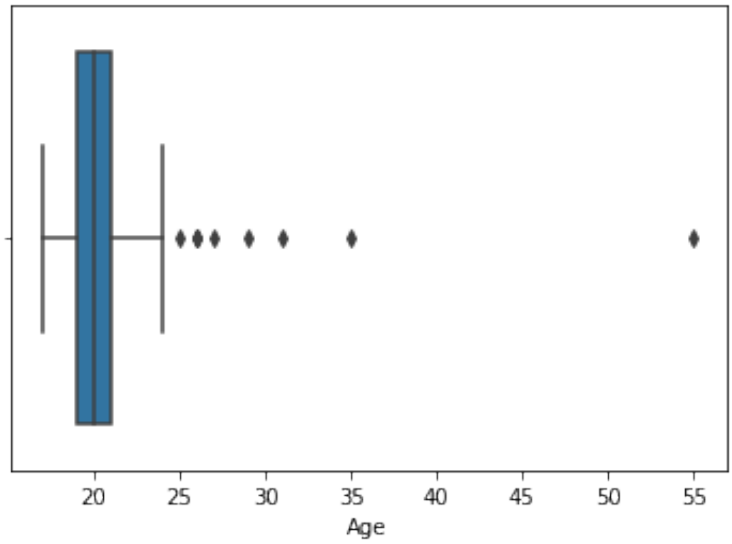


```
sns.boxplot(df['Growth'])
```

```
/usr/local/lib/python3.7/dist-packages/seaborn/_decorators.py:43: FutureWar
  FutureWarning
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac4a3e450>
```

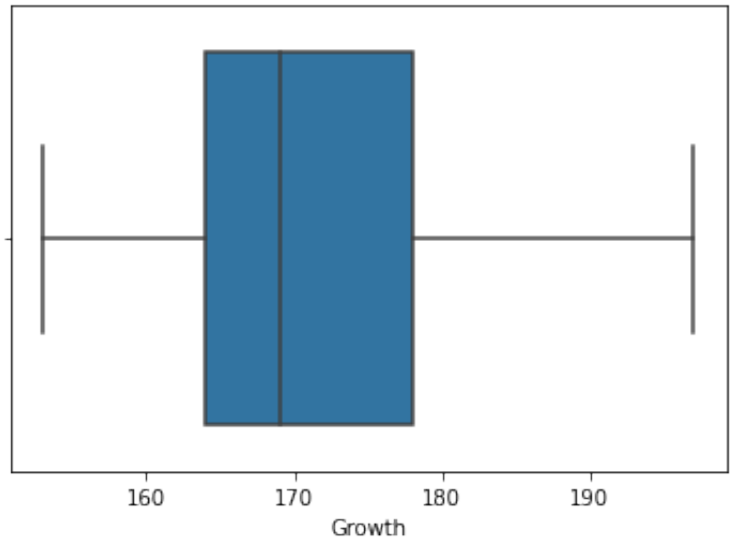

```
sns.boxplot(df['Weight'])
```

```
/usr/local/lib/python3.7/dist-packages/seaborn/_decorators.py:43: FutureWar
  FutureWarning
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac49979d0>
```

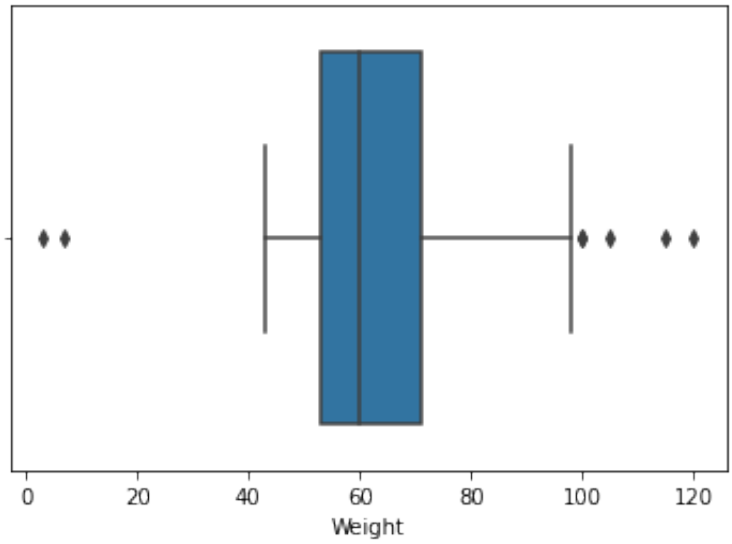

1 метод удаления выбросов

Найти среднее значение m

Найти СКО s

Построить интервал m-3s; m+3s, все наблюдения за пределами интервала удалить из таблицы

То есть используется простейшее правило трех сигм, которое покрывает 99% значений

```
m = df['Weight'].mean()
```

```
s = df['Weight'].std()
```

```
m - 3 * s, m + 3 * s
```

```
(14.52494740231539, 113.53874686520054)
```

```
df = df[(df['Weight'] > m - 3 * s) & (df['Weight'] < m + 3 * s)]
```

```
sns.boxplot(df['Weight'])
```

```
/usr/local/lib/python3.7/dist-packages/seaborn/_decorators.py:43: FutureWar
  FutureWarning
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac4916190>
```

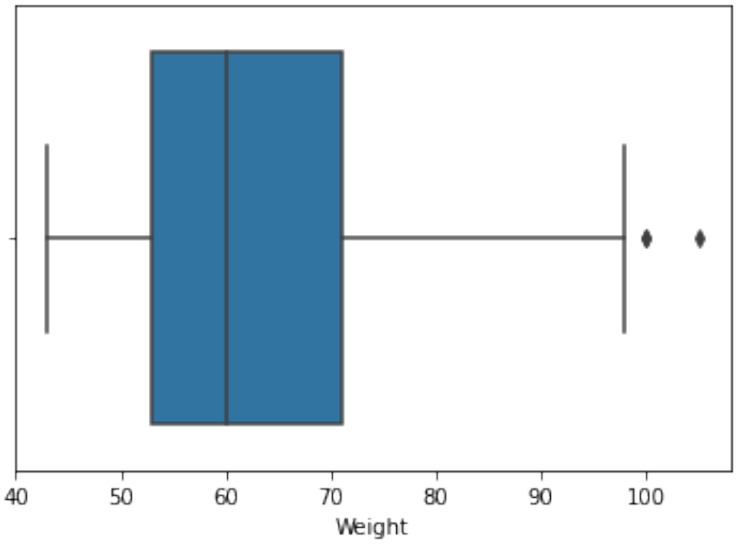

2 способ

a - 25 процентиль

b - 75 процентиль

Строится интервал вида a - 1.5(b - a); b + 1.5(b - a)

Наблюдения за пределами также удаляются

```
df = pd.read_csv('/content/drive/MyDrive/Colab Notebooks/students.csv',
                 delimiter=',')
sns.boxplot(df.Age)
```

```
/usr/local/lib/python3.7/dist-packages/seaborn/_decorators.py:43: FutureWar
  FutureWarning
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac4a25910>
```

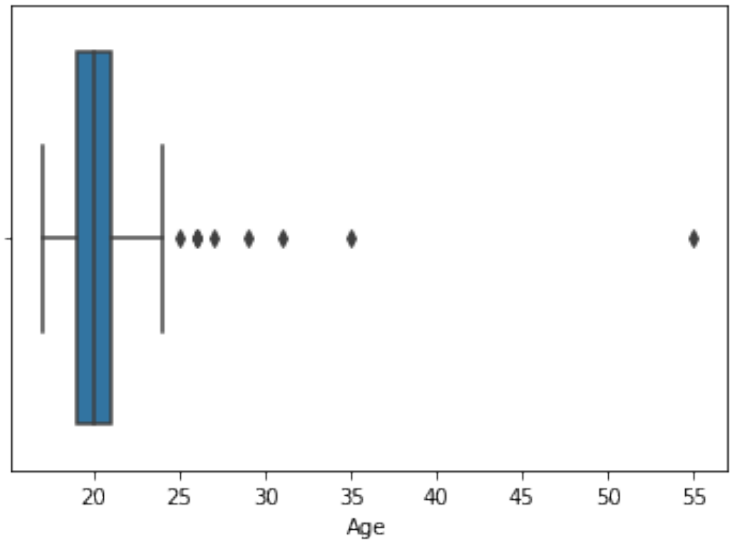


```
a = df['Age'].quantile(0.25)
b = df['Age'].quantile(0.75)
```

```
df = df[(df['Age'] > a - 1.5 * (b - a)) & (df['Age'] < b + 1.5 * (b - a))]
```

```
sns.boxplot(df['Age'])
```

```
/usr/local/lib/python3.7/dist-packages/seaborn/_decorators.py:43: FutureWar
  FutureWarning
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac486cf50>
```

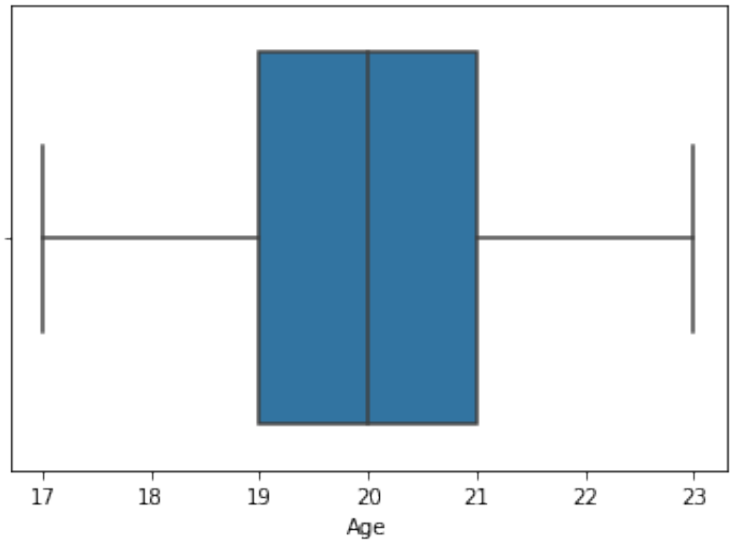

Кластеризация

```
from sklearn.cluster import KMeans

df_cut = df[['Weight', 'Growth', 'Sex']]

df_cut = df_cut.dropna()

kmeans = KMeans(n_clusters=2, random_state=0)
kmeans.fit(df_cut[['Weight', 'Growth']])
df_cut['Label'] = kmeans.labels_
```

```
df_cut.head()
```

	Weight	Growth	Sex	Label
0	64.0	170	женский	1
1	73.0	191	мужской	0
2	60.0	172	мужской	1
3	59.0	168	женский	1
4	57.0	159	женский	1

```
sns.scatterplot(data=df_cut, x='Weight', y='Growth', hue='Label')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac4240490>
```

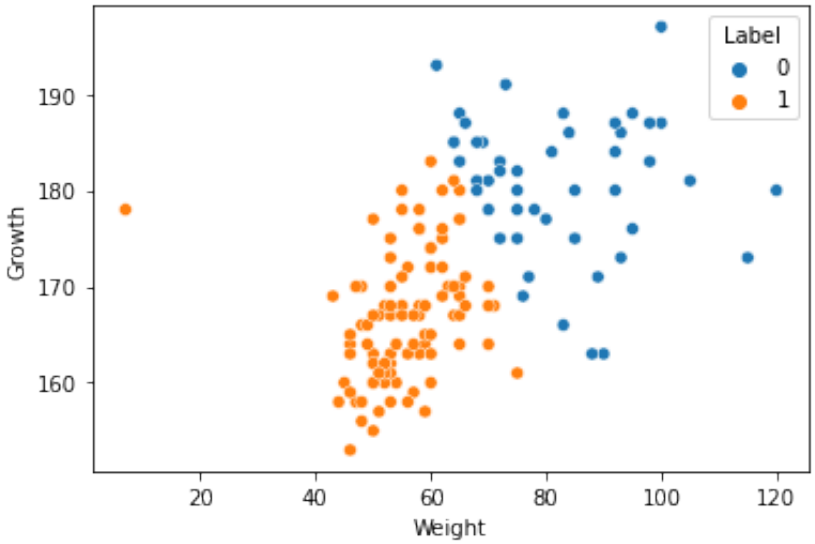

Сравним с разбиением по полу

```
sns.scatterplot(data=df_cut, x='Weight', y='Growth', hue='Sex')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac2c1cf90>
```

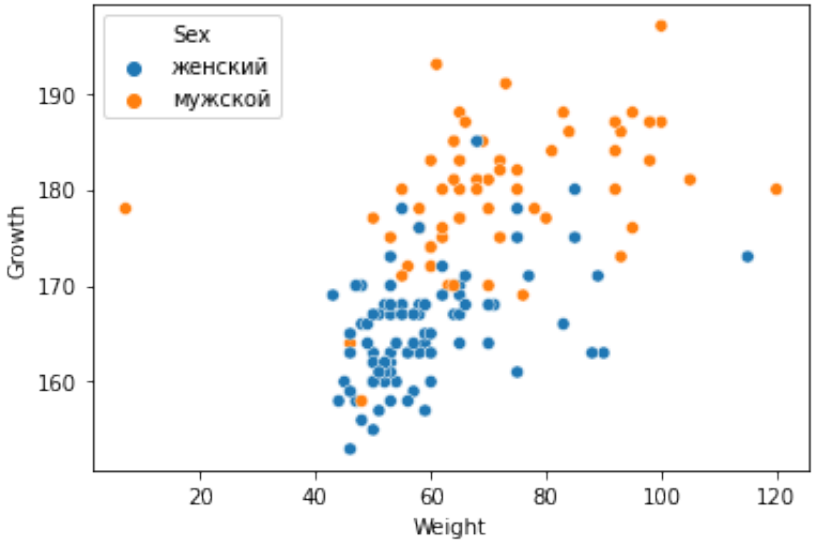

Пример простейшей проверки точности кластеризации

```
sum((df_cut['Sex'] == 'мужской') & df_cut['Label'] == 1)
```

```
24
```

24 ошибки в определении мужчин

```
kmeans = KMeans(n_clusters=3, random_state=0)
kmeans.fit(df_cut[['Weight', 'Growth']])
df_cut['Label'] = kmeans.labels_
```

```
sns.scatterplot(data=df_cut, x='Weight', y='Growth', hue='Label')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac2b8a910>
```

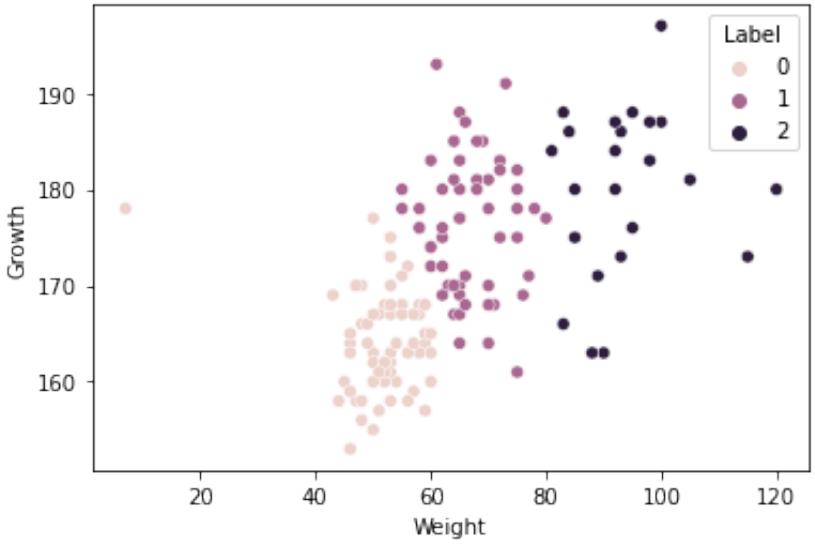

Базовые методы машинного обучения

Предсказание (классификация - категориальный признак) и регрессия (числовой признак)

Линейная регрессия

```
df_cut = df[['Growth', 'Shoe size']]
df_cut = df_cut.dropna()
```

```
from sklearn.linear_model import LinearRegression
```

```
sns.scatterplot(data=df_cut, x='Shoe size', y='Growth')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac2b25210>
```

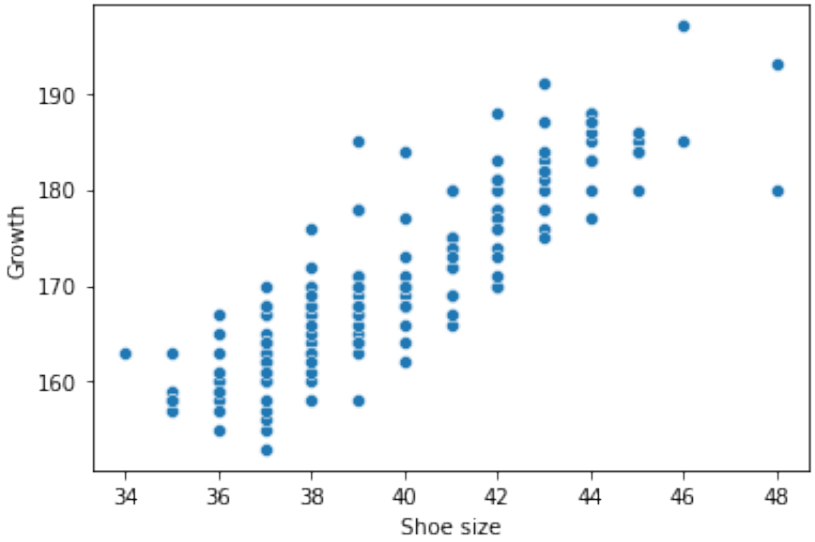

Просматривается линейная зависимость, значит можно прменять линейную регрессию.

Целевой признак - рост

```
linearRegression = LinearRegression()
results = linearRegression.fit(df_cut['Shoe size'].values.reshape(-1, 1),
                               y=df_cut['Growth'].values)
```

```
results.coef_, results.intercept_ # коэффициент и свободный член
```

```
(array([2.77966583]), 60.26465138793836)
```

```
df_cut['Predicted Growth'] = results.predict(df_cut['Shoe size'].values.reshape(
```

```
df_cut.head()
```

	Growth	Shoe size	Predicted Growth
0	170	40	171.451284
1	191	43	179.790282
2	172	41	174.230950
3	168	38	165.891953
4	159	36	160.332621

Проверим точность предсказаний, посчитаем среднюю абсолютную ошибку

```
from sklearn.metrics import mean_absolute_error
mean_absolute_error(df_cut['Growth'], df_cut['Predicted Growth'])
```

```
3.4686666590527797
```

Теперь множественная линейная регрессия

```
df_cut = df[['MIddle and index finger',
             'Middle and ring finger',
             'Middle and little finger']]
```

```
df_cut
```

	MIddle and index finger	Middle and ring finger	Middle and little finger
0	20	10.0	40.0
1	5	5.0	20.0
2	13	10.0	26.0
3	12	13.5	35.0
4	10	11.0	22.0
...	...	...	...
181	13	23.0	45.0
182	8	9.0	15.0
183	9	16.0	35.0
184	9	15.0	25.0
185	7	10.0	35.0

171 rows × 3 columns

```
results = linearRegression.fit(df_cut[['Middle and ring finger', 'Middle and lit
                               y=df_cut['MIddle and index finger'].values)
results.coef_, results.intercept_
```

```
(array([0.11527745, 0.04296171]), 7.4077839882224925)
```

Итоговая модель:

MIddle and index finger = 0.115 * Middle and ring finger + 0.043 * Middle and little finger + 7.41

```
df_cut['Predicted'] = results.predict(df_cut[['Middle and ring finger', 'Middle
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: SettingWith
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs
  """Entry point for launching an IPython kernel.
```

```
mean_absolute_error(df_cut['MIddle and index finger'], df_cut['Predicted'])
```

```
3.1885190843328126
```

Проверка точности модели на новой выборке Предыдущие тесты точности алгоритма были не совсем верными, так как модель обучалась и проверялась на одних и тех же данных

Далее рассказывается о стандартном подходе разделения на тренировочную и тестовую выборку

Здесь будут использоваться два датасета

```
df_test = pd.read_csv('/content/drive/MyDrive/Colab Notebooks/students_test.csv'
                      delimiter=',')
```

```
df_test_cut = df_test[['MIddle and index finger',
                       'Middle and ring finger',
                       'Middle and little finger']]
```

Используем функцию predict на тестовую выборку

```
df_test_cut['Predicted'] = results.predict(df_test_cut[['Middle and ring finger'
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: SettingWith
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs
  """Entry point for launching an IPython kernel.
```

```
mean_absolute_error(df_test_cut['Predicted'], df_test_cut['MIddle and index fing
```

```
4.68045833086758
```

Алгоритмы классификации

Метод k ближайших соседей (kNN)

```
from sklearn.neighbors import KNeighborsClassifier
```

```
df_cut = df[['Growth', 'Weight', 'Sex']]
df_cut = df_cut.dropna()
```

```
sns.scatterplot(data=df_cut, x='Weight', y='Growth', hue='Sex')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac2b25450>
```

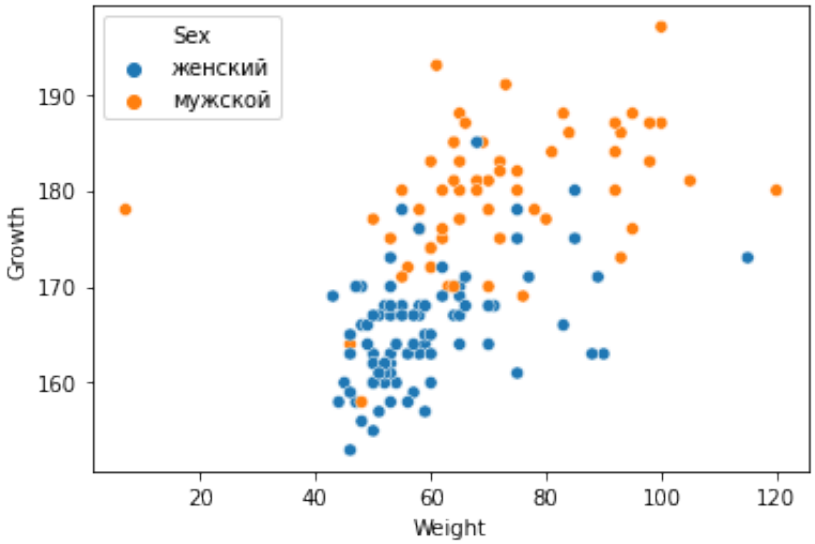

Для корректного подсчета расстояний необходимо провести нормировку данных

```
from sklearn.preprocessing import StandardScaler
```

```
scaler = StandardScaler()
```

```
# обучение нормировщика
scaler.fit(df_cut[['Weight', 'Growth']].values.reshape(-1, 2))
```

```
StandardScaler()
```

```
# нормировка
arr = scaler.transform(df_cut[['Weight', 'Growth']].values.reshape(-1, 2))
```

В итоге данные превращаются в обезличенный массив

```
arr
```

```
array([[-0.01667202, -0.1499425 ],
       [ 0.54119943,  2.09919504],
       [-0.26461489,  0.06426107],
       [-0.3266006 . -0.36414608].
```

```
[-0.45057203, -1.32806217],
[-0.88447205,  0.59977001],
[-0.57454347,  0.92107538],
[ 3.45452809,  0.92107538],
[ 0.29325656,  1.45658432],
[-0.38858632, -0.36414608],
[-1.0704292 , -1.43516396],
[ 2.09084234,  1.24238074],
[-1.00844348, -0.57834966],
[-0.01667202,  1.45658432],
[-0.26461489,  1.24238074],
[-0.6985149 , -0.47124787],
[-0.3266006 , -0.79255323],
[ 1.78091375,  1.5636861 ],
[-0.57454347, -0.36414608],
[-0.51255775, -1.43516396],
[ 0.0453137 ,  1.77788968],
[ 0.0453137 ,  0.59977001],
[ 0.35524228, -0.79255323],
[-0.26461489, -0.89965502],
[-0.20262917,  2.31339862],
[ 1.5949566 , -0.89965502],
[ 0.35524228,  1.02817716],
[ 0.0453137 , -0.1499425 ],
[ 1.90488519,  1.77788968],
[-0.01667202,  1.45658432],
[ 0.0453137 ,  0.59977001],
[-0.6985149 , -1.00675681],
[ 1.22304231,  1.5636861 ],
[-0.3266006 , -0.68545144],
[ 0.66517086, -1.11385859],
[ 0.23127085,  1.45658432],
[-1.00844348, -0.1499425 ],
[ 0.23127085,  1.02817716],
[ 0.47921371,  1.24238074],
[-0.14064345,  0.92107538],
[-0.38858632,  0.49266822],
[-0.14064345,  0.06426107],
[ 0.35524228,  0.7068718 ],
[ 0.66517086,  0.38556644],
[-0.6985149 , -0.89965502],
[-1.00844348, -1.64936753],
[ 1.71892804,  0.92107538],
[-0.38858632, -0.89965502],
[ 0.72715658, -0.25704429],
[ 0.0453137 , -0.25704429],
[-0.07865774, -0.1499425 ],
[-0.6985149 , -0.1499425 ],
[ 0.66517086,  1.13527895],
[ 0.10729941,  1.67078789],
[-0.38858632,  0.7068718 ],
[ 0.85112801,  0.7068718 ],
[ 0.0453137 ,  0.92107538],
[ 2.52474235,  1.02817716],
```

```
[-0.88447205, -0.89965502],
```

Сама классификация

```
model = KNeighborsClassifier(n_neighbors=1) # инициализация
model.fit(arr, y=df_cut['Sex'].values)
```

```
KNeighborsClassifier(n_neighbors=1)
```

Модель обучена, можно проверять ее на тестовой выборке

```
df_test_cut = df_test[['Growth', 'Weight', 'Sex']]
df_test_cut = df_test_cut.dropna()
```

```
arr_test = scaler.transform(df_test_cut[['Weight', 'Growth']].values.reshape(-1,
```

```
df_test_cut['Predicted'] = model.predict(arr_test)
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: SettingWith
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs
  """Entry point for launching an IPython kernel.
```

```
df_test_cut.head()
```

	Growth	Weight	Sex	Predicted
0	180.0	78.0	мужской	мужской
1	167.0	50.0	женский	женский
2	178.0	70.0	женский	мужской
3	156.0	47.0	женский	женский
4	186.0	94.0	мужской	мужской

Метрики качества алгоритма классификации

Матрица сопряженности

```
pd.crosstab(df_test_cut['Sex'], df_test_cut['Predicted'])
```

Predicted	женский	мужской
Sex		
женский	39	8
мужской	3	27

Закодируем результаты

```
df_test_cut['Code'] = 0
df_test_cut.loc[(df_test_cut['Sex'] == 'мужской') & (df_test_cut['Predicted'] ==
df_test_cut.loc[(df_test_cut['Sex'] == 'женский') & (df_test_cut['Predicted'] ==
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: SettingWith
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs
  """Entry point for launching an IPython kernel.
/usr/local/lib/python3.7/dist-packages/pandas/core/indexing.py:1817: Settin
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs
  self._setitem_single_column(loc, value, pi)
```

```
sns.scatterplot(data=df_test_cut, x='Weight', y='Growth', hue='Code')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac2996cd0>
```

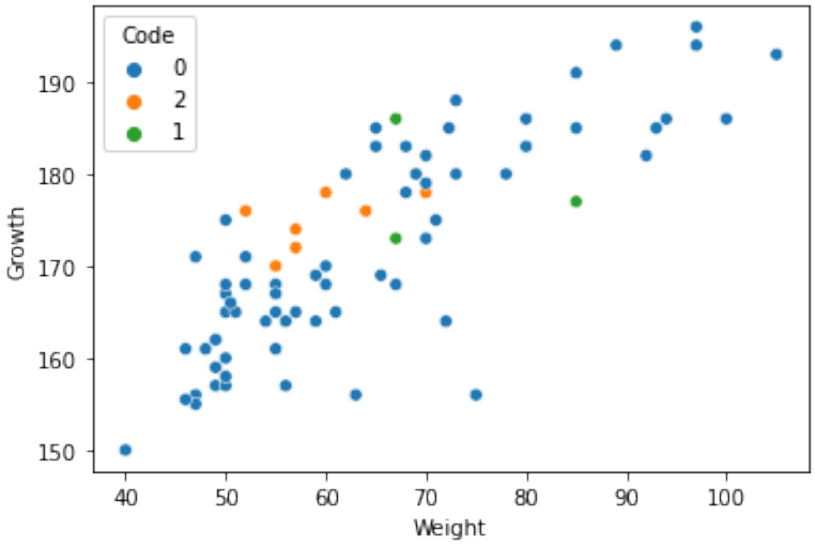

Линейный классификатор

```
from sklearn.linear_model import SGDClassifier
```

```
sns.scatterplot(data=df_cut, x='Weight', y='Growth', hue='Sex')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac2929bd0>
```

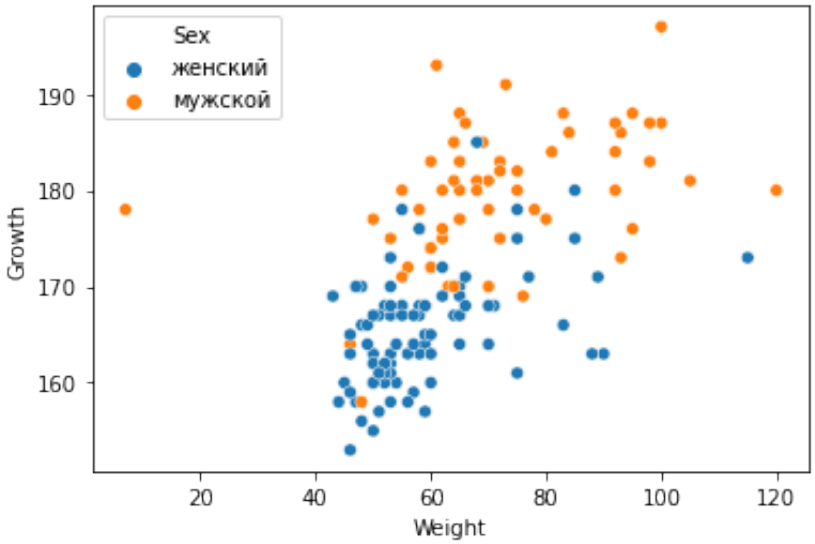

Задача линейного классификатора - разделить данные на группы прямой линией

```
scaler.fit(df_cut[['Weight', 'Growth']].values.reshape(-1, 2))
arr = scaler.transform(df_cut[['Weight', 'Growth']].values.reshape(-1, 2))
```

```
model = SGDClassifier()
```

```
model.fit(arr, y=df_cut['Sex'].values)
```

```
SGDClassifier()
```

```
df_test_cut = df_test[['Growth', 'Weight', 'Sex']]
```

```
df_test_cut = df_test_cut.dropna()
```

```
arr_test = scaler.transform(df_test_cut[['Weight', 'Growth']].values.reshape(-1,
```

```
df_test_cut['Predicted'] = model.predict(arr_test)
```

```
pd.crosstab(df_test_cut['Predicted'], df_test_cut['Sex'])
```

Sex	женский	мужской
Predicted		
женский	44	4
мужской	3	26

```
df_test_cut['Code'] = 0
df_test_cut.loc[(df_test_cut['Sex'] == 'мужской') & (df_test_cut['Predicted'] ==
df_test_cut.loc[(df_test_cut['Sex'] == 'женский') & (df_test_cut['Predicted'] ==
```

```
sns.scatterplot(data=df_test_cut, x='Weight', y='Growth', hue='Code')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f9ac2a31690>
```

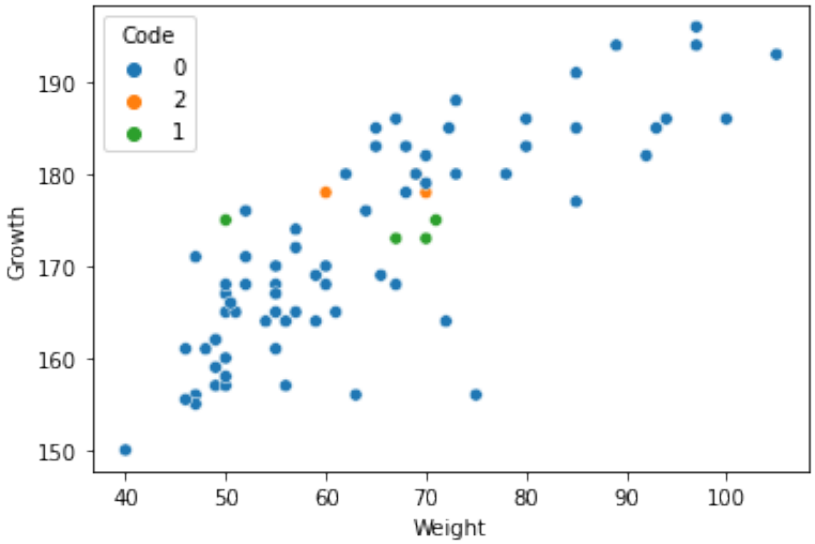

Вероятностные алгоритмы

Вместо предсказания дают вероятность принадлежности к одному или другому классу

```
from sklearn.ensemble import RandomForestClassifier
```

```
df_cut = df[['Growth', 'Weight', 'Sex', 'Hair length', 'Children number']]
df_cut = df_cut.dropna()
```

```
model = RandomForestClassifier(max_depth=2, random_state=0)


model.fit(df_cut[['Growth', 'Weight', 'Hair length', 'Children number']].values.
          y=df_cut['Sex'].values)
```

```
    RandomForestClassifier(max_depth=2, random_state=0)
```

```
df_test_cut = df_test[['Growth', 'Weight', 'Sex', 'Hair length', 'Children numbe
df_test_cut = df_test_cut.dropna()
```

Для получения вероятности используем метод **predict_proba**

```
result = model.predict_proba(df_test_cut[['Growth', 'Weight', 'Hair length', 'Ch
print(result)
```

```
    [[0.05717479 0.94282521]
     [0.95703983 0.04296017]
     [0.92220778 0.07779222]
     [0.94430864 0.05569136]
     [0.04557862 0.95442138]
     [0.95326172 0.04673828]
     [0.95058413 0.04941587]
     [0.20051871 0.79948129]
     [0.08046935 0.91953065]
     [0.60783415 0.39216585]
     [0.70492419 0.29507581]
     [0.06705782 0.93294218]
     [0.6689992  0.3310008 ]
     [0.96331532 0.03668468]
     [0.96513351 0.03486649]
     [0.05959696 0.94040304]
     [0.14395969 0.85604031]
     [0.03395659 0.96604341]
     [0.96193671 0.03806329]
     [0.05959696 0.94040304]
     [0.03654891 0.96345109]
     [0.03654891 0.96345109]
     [0.10687531 0.89312469]
     [0.95703983 0.04296017]
     [0.92891486 0.07108514]
     [0.68630715 0.31369285]
     [0.07115209 0.92884791]
     [0.10142245 0.89857755]
     [0.93072869 0.06927131]
     [0.96513351 0.03486649]
     [0.95507991 0.04492009]
     [0.93724458 0.06275542]
     [0.9646143  0.0353857 ]
     [0.9361299  0.0638701 ]
```

```
[0.9561299  0.0438701 ]
[0.12028684 0.87971316]
[0.04479506 0.95520494]
[0.0434047  0.9565953 ]
[0.06923173 0.93076827]
[0.96279612 0.03720388]
[0.9646143  0.0353857 ]
[0.9646143  0.0353857 ]
[0.93359305 0.06640695]
[0.95703983 0.04296017]
[0.12121668 0.87878332]
[0.96513351 0.03486649]
[0.56588125 0.43411875]
[0.0434047  0.9565953 ]
[0.9646143  0.0353857 ]
[0.88054449 0.11945551]
[0.93241863 0.06758137]
[0.95703983 0.04296017]
[0.9646143  0.0353857 ]
[0.82292556 0.17707444]
[0.96193671 0.03806329]
[0.93259282 0.06740718]
[0.89663671 0.10336329]
[0.72626932 0.27373068]
[0.9347861  0.0652139 ]
[0.03395659 0.96604341]
[0.20051871 0.79948129]
```

Получили вероятности принадлежности к классу

```
df_test_cut['pr class 0'] = result[:, 0]
df_test_cut['pr class 1'] = result[:, 1]
df_test_cut.head()
```

	Growth	Weight	Sex	Hair length	Children number	pr class 0	pr class 1
0	180.0	78.0	мужской	1.2	2.0	0.057175	0.942825
1	167.0	50.0	женский	30.0	2.0	0.957040	0.042960
3	156.0	47.0	женский	20.0	2.0	0.922208	0.077792
5	150.0	40.0	женский	30.0	2.0	0.944309	0.055691
7	183.0	80.0	мужской	2.0	0.0	0.045579	0.954421

Селекция признаков

Использование нецелевых категориальных признаков

```
from sklearn import tree
```

Заменим признак категориальный признак пола числами, для этого просто кодируем разные метки нулями и единицами

```
from sklearn import preprocessing

coder = preprocessing.LabelEncoder()

coder.fit(df['Sex'])
```

```
    LabelEncoder()
```

```
coder.transform(df['Sex'])
```

```
    array([0, 1, 1, 0, 0, 1, 1, 1, 1, 0, 0, 1, 0, 0, 1, 0, 1, 1, 0, 0, 1, 0,
           0, 1, 1, 0, 0, 1, 0, 0, 1, 0, 0, 1, 0, 1, 1, 0, 1, 0, 0, 0, 0, 1,
           1, 1, 0, 1, 0, 1, 0, 0, 0, 0, 1, 0, 1, 0, 1, 0, 1, 1, 1, 0, 1, 1,
           0, 1, 0, 0, 0, 1, 0, 1, 1, 0, 1, 0, 1, 1, 0, 0, 1, 0, 0, 0, 0, 1,
           1, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 0, 0, 0, 0, 1, 1, 1, 1, 0,
           0, 0, 1, 0, 1, 0, 0, 1, 0, 0, 1, 1, 0, 0, 1, 0, 0, 0, 0, 0, 1, 0,
           0, 0, 1, 0, 0, 0, 0, 0, 1, 0, 1, 0, 1, 0, 0, 1, 0, 0, 0, 0, 0, 0,
           0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0])
```

```
df1 = df
df1['Sex'] = coder.transform(df1['Sex'])

for name in ['Coin', 'Animal', 'Army']:
  coder.fit(df1[name])
  df1[name] = coder.transform(df1[name])

df_cut = df1[['Growth', 'Weight', 'Sex', 'Hair length',
              'Coin', 'Children number', 'Animal', 'Army']]

df_cut = df_cut.dropna()
```

```
model = tree.DecisionTreeClassifier(max_depth=4)
model.fit(df_cut[['Growth', 'Weight', 'Hair length', 'Children number',
                  'Coin', 'Animal', 'Army']].values.reshape(-1, 7),
          y=df_cut['Sex'].values)
```

```
DecisionTreeClassifier(max_depth=4)
```

Визуализация результатов

```
import graphviz


dot_data = tree.export_graphviz(model, out_file=None,
                                feature_names=['Growth', 'Weight', 'Hair length'
                                               'Children number', 'Coin', 'Anima
                                               'Army'],
                                class_names=['f', 'm'],
                                filled=True,
                                rounded=True,
                                special_characters=True
                                )
graph = graphviz.Source(dot_data)
graph
```

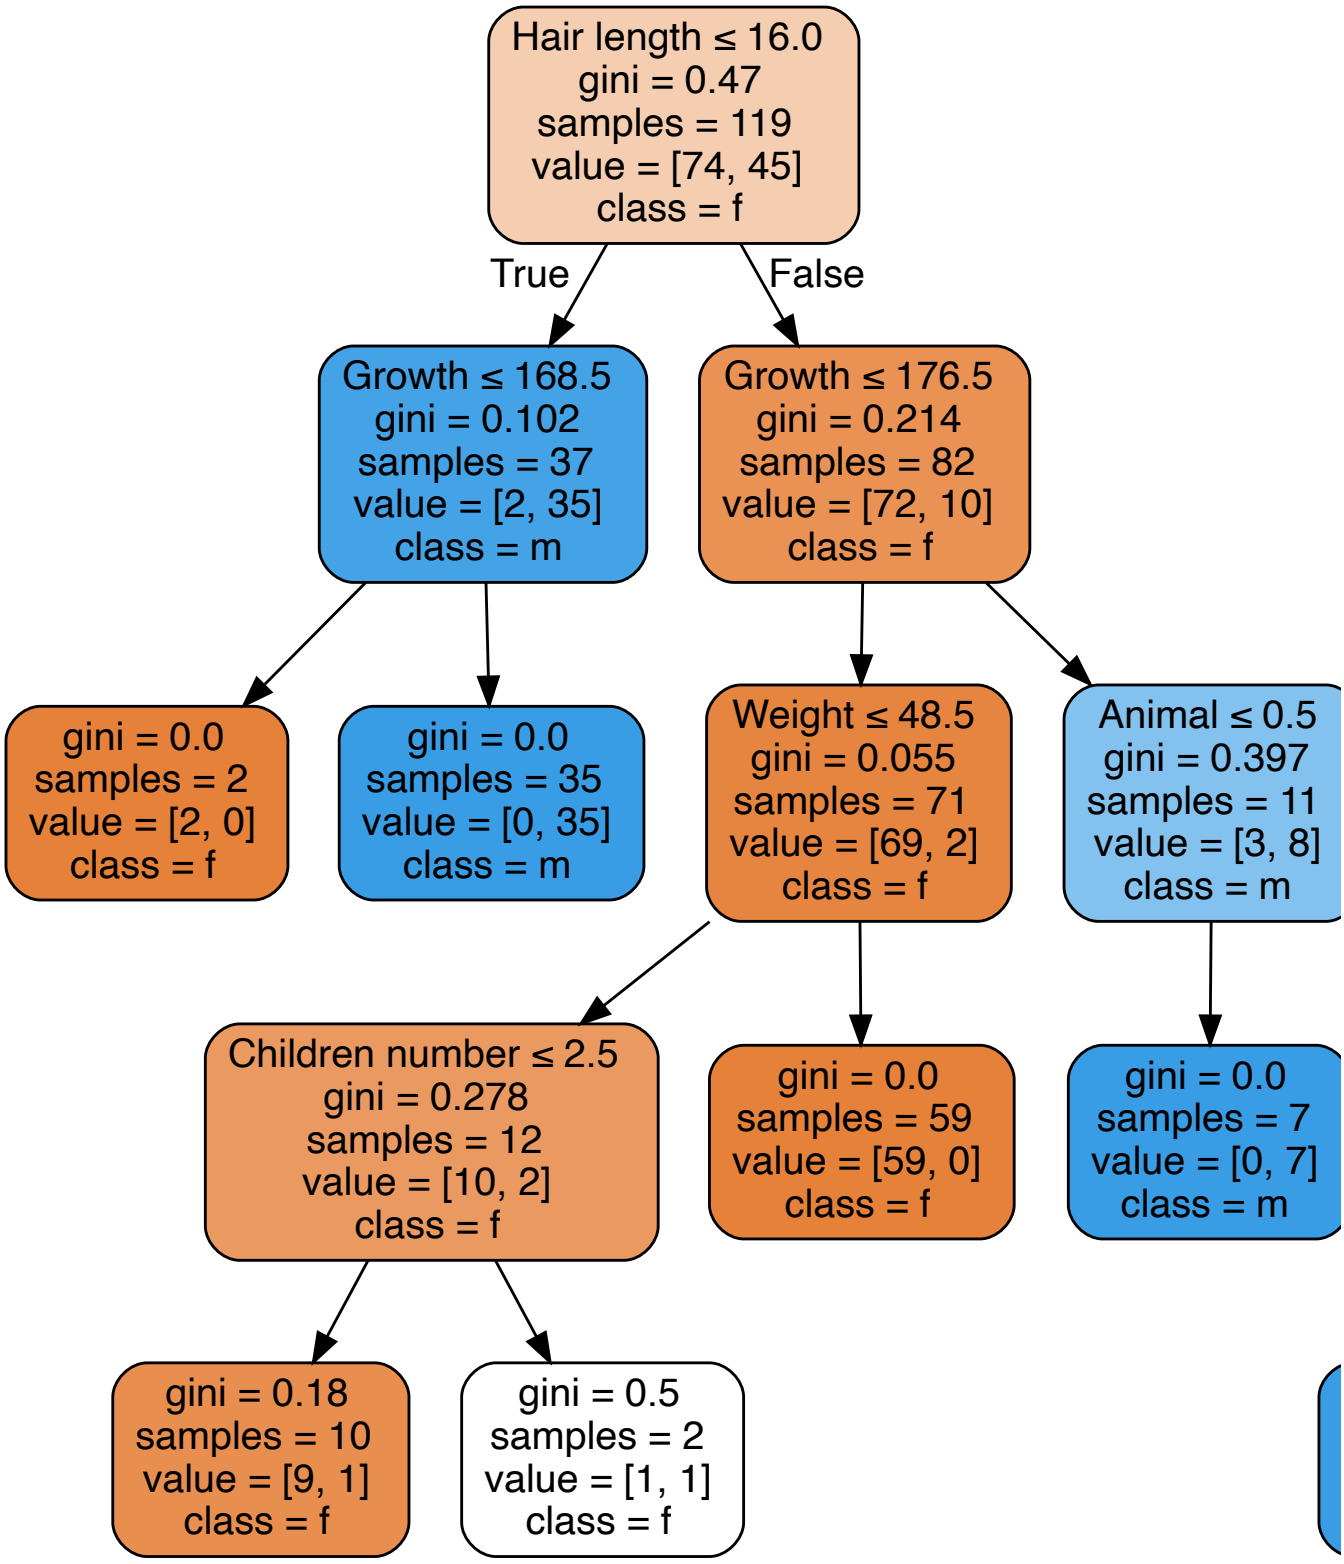


```
df_test_cut = df_test[['Growth', 'Weight', 'Sex',
                       'Hair length', 'Children number',
                       'Coin', 'Animal', 'Army']]

df_test_cut = df_test_cut.dropna()
```

```
for name in['Sex', 'Animal', 'Army', 'Coin']:
  coder.fit(df_test_cut[name])
  df_test_cut[name] = coder.transform(df_test_cut[name])
```

```
df_test_cut['Predict'] = model.predict(df_test_cut[['Growth', 'Weight', 'Coin',
                                                    'Hair length', 'Army', 'Anim
                                                    'Children number']].values.r
```

```
quality = pd.crosstab(df_test_cut['Predict'], df_test_cut['Sex'])
quality
```

Sex	0	1
Predict		
0	30	0
1	12	26

```
# recall (ж) – доля правильно предсказанных женщин
quality[0][0] / sum(quality[0])
```

```
0.7142857142857143
```

```
# recall (м)
quality[1][1] / sum(quality[1])
```

```
1.0
```

```
# precision (ж) – доля истинных женщин среди людей, которых классификатор отнес
quality[0][0] / (quality[0][0] + quality[1][0])
```

```
1.0
```

```
# precision (м)
quality[1][1] / (quality[1][1] + quality[0][1])
```

```
0.6842105263157895
```

Кодирование категориальных признаков и их полезность

```
coder = preprocessing.LabelEncoder()
```

```
df = pd.read_csv('/content/drive/MyDrive/Colab Notebooks/students.csv',
                 delimiter=',')
```

Переведем все категории в числа

```
df1 = df.dropna()
for name in ['Sex', 'Coin', 'Animal', 'Army', 'Glasses',
             'Your rating in university', 'Fastfood',
             'Hostel', 'Chocolate', 'Brother-sister',
             'Plane seat', 'Problems in last semester',
             'Rock paper scissors', 'Strange people',
             'Your insitute']:
             coder.fit(df1[name])
             df1[name] = coder.transform(df1[name])
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:9: SettingWith
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs
  if __name__ == '__main__':
```

Проверим важность признаков

```
from sklearn.ensemble import ExtraTreesClassifier
```

```
selector = ExtraTreesClassifier()
result = selector.fit(df1[df1.columns], df1['Sex'])
result.feature_importances_
```

```
array([0.00486312, 0.05612654, 0.1077762 , 0.00277149, 0.004382  ,
       0.00374471, 0.01107933, 0.00502965, 0.01358079, 0.02781332,
       0.00137147, 0.00303761, 0.0038468 , 0.00117425, 0.0059186 ,
       0.00166235, 0.00488792, 0.00341772, 0.00588856, 0.00385442,
       0.00341795, 0.0133458 , 0.0073797 , 0.41186935, 0.00735933,
       0.02651898, 0.00213353, 0.00393967, 0.00334157, 0.00258795,
       0.00384484, 0.00422083, 0.00554578, 0.0071112 , 0.09920971,
       0.00242854, 0.06129814, 0.0059842 , 0.0042773 , 0.00561605,
       0.00609938, 0.00336402, 0.00399035, 0.00661712, 0.00565334,
       0.00348775, 0.01189274, 0.00523805])
```

```
features_table = pd.DataFrame(result.feature_importances_, index=df1.columns,
                              columns=['Importance'])


features_table.sort_values(by='Importance', ascending=False)
```

	Importance
Sex	0.411869
Shoe size	0.107776
Army	0.099210
Hair length	0.061298
Growth	0.056127
Computer science rating	0.027813
Coin	0.026519
Physics rating	0.013581
Weight	0.013346
Middle and ring finger	0.011893
Russian rating	0.011079
Glasses	0.007380
Problems in last semester	0.007359
Putin age	0.007111
Brother-sister	0.006617
City population	0.006099
Floor number	0.005984
Biology rating	0.005919
Minutes to first class	0.005889
Plane seat	0.005653
Chocolate	0.005616
Width of 5000 mm	0.005546
Middle and little finger	0.005238
Maths rating	0.005030
Social science rating	0.004888

Age	0.004863
Year of birth	0.004382
Social network duration min	0.004277
Height of 5000 mm	0.004221
Your insitute	0.003990
Animal	0.003940

Видим убывающий список наиболее эффективных признаков, описывающих пол человека

Mlddle and index finger	0.003488

Оставим только часть значимых признаков

```
df_cut = df[['Army', 'Shoe size', 'Hair length', 'Growth',
             'Coin', 'Computer science rating', 'Weight', 'Sex']]
df_cut = df_cut.dropna()
```

Strange people	0.003364

Другой способ кодирования категориальных признаков

```
df_cut = pd.get_dummies(df_cut)
df_cut.head()
```

	Shoe size	Hair length	Growth	Computer science rating	Weight	Army_могут призвать	Army_не призовут (по разным причинам)	Coin_Орел
0	40	50.0	170	84	64.0	0	1	1
1	43	7.0	191	72	73.0	0	1	1
2	41	4.0	172	0	60.0	1	0	0
3	38	20.0	168	0	59.0	0	1	0

Получили дополнительные столбцы с различными вариантами ответов

Теперь удалим лишние столбцы, тк, например, в случае пола, нам хватит только столбца с одним полом, чтобы знать данные по каждому полу

```
df_cut = df[['Army', 'Shoe size', 'Hair length', 'Growth',
             'Coin', 'Computer science rating', 'Weight', 'Sex']]
df_cut = df_cut.dropna()
df_cut = pd.get_dummies(df_cut, drop_first=True)
df_cut.head()
```

	Shoe size	Hair length	Growth	Computer science rating	Weight	Army_не призовут (по разным причинам)	Coin_Решка	Sex_мужской
0	40	50.0	170	84	64.0	1	0	0
1	43	7.0	191	72	73.0	1	0	1
2	41	4.0	172	0	60.0	0	1	1

Удалили избыточность

```
model = tree.DecisionTreeClassifier(max_depth=3)
model.fit(df_cut[['Army_не призовут (по разным причинам)',
                  'Shoe size',
                  'Growth',
                  'Hair length',
                  'Coin_Решка',
                  'Computer science rating',
                  'Weight']].values.reshape(-1, 7),
          y=df_cut['Sex_мужской'])
```

```
DecisionTreeClassifier(max_depth=3)
```

```
dot_data = tree.export_graphviz(model, out_file=None,
                                feature_names=['Army_не призовут (по разным прич
                'Shoe size',
                'Growth',
                'Hair length',
                'Coin_Решка',
                'Computer science rating',
                'Weight'],
                class_names=['f', 'm'],
                filled=True, rounded=True,
                special_characters=True)
graph = graphviz.Source(dot_data)
graph
```

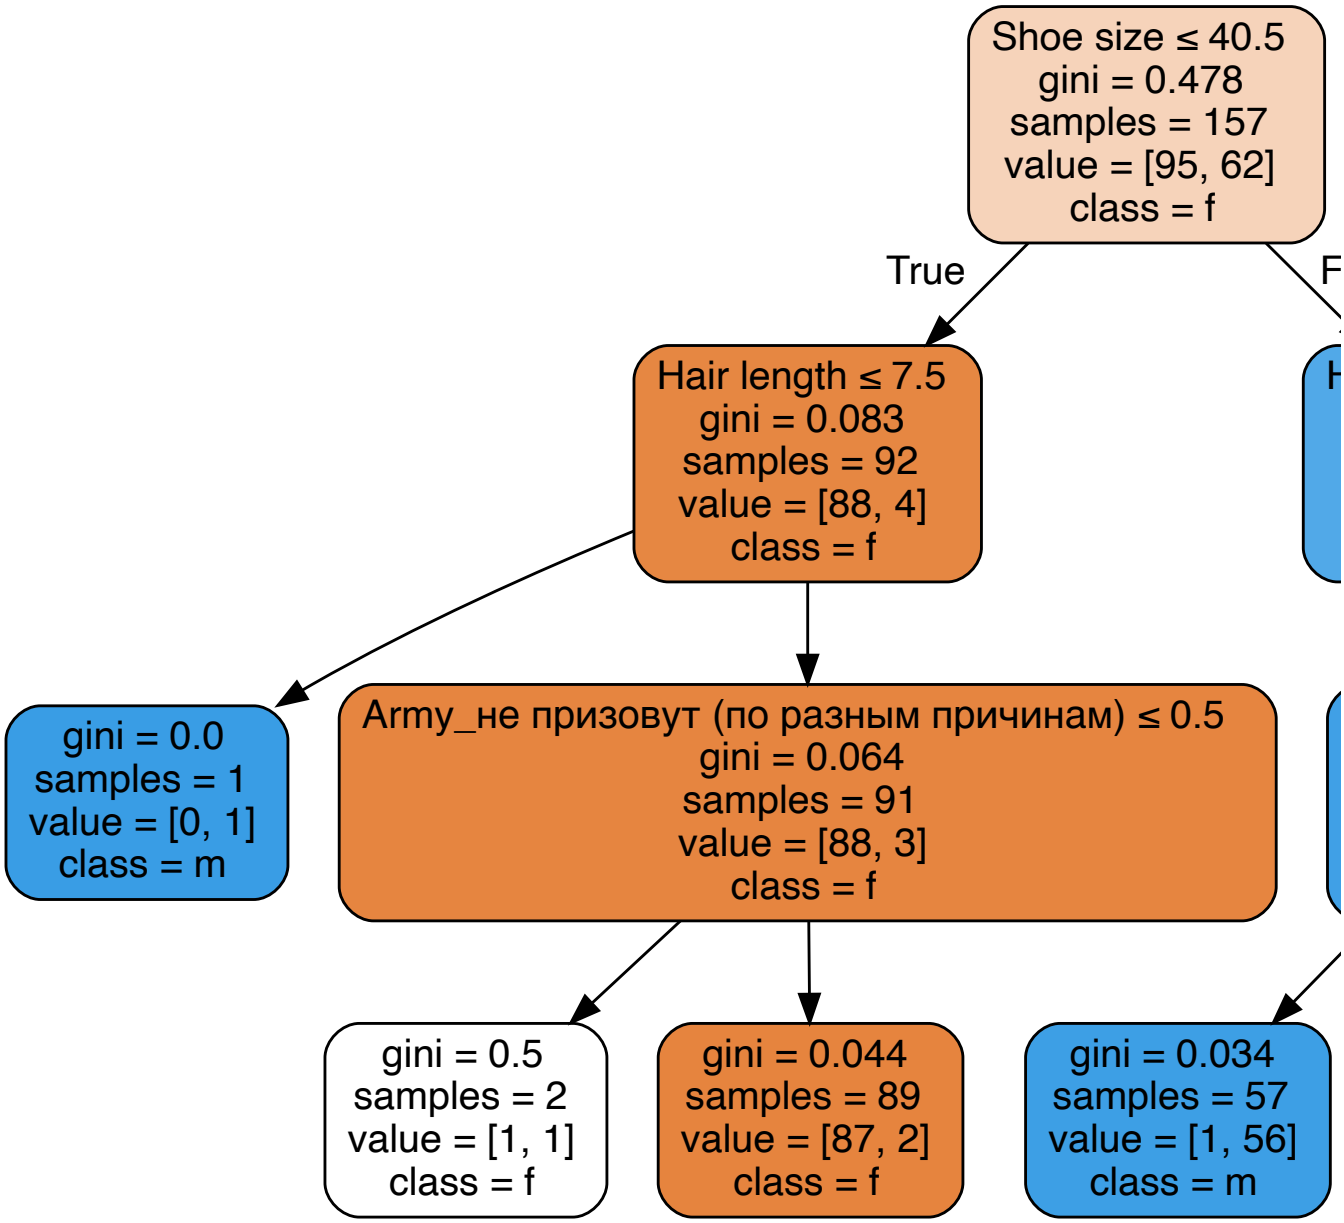

```
df_test_cut = df_test[['Army', 'Shoe size', 'Hair length', 'Coin',
                       'Computer science rating', 'Weight', 'Sex',
                       'Growth']]
df_test_cut = df_test_cut.dropna()
```

```
df_test_cut = pd.get_dummies(df_test_cut, drop_first=True)
df_test_cut.head()
```

	Shoe size	Hair length	Computer science rating	Weight	Growth	Army_не призовут (по разным причинам)	Coin_Решка	Sex_мужской
0	44.0	1.2	88	78.0	180.0	1	0	1
1	38.0	30.0	0	50.0	167.0	1	0	0
2	41.0	50.0	0	70.0	178.0	1	0	0

```
df_test_cut['Predict'] = model.predict(df_test_cut[['Army_не призовут (по разным
                 'Shoe size',
                 'Growth',
                 'Hair length',
                 'Coin_Решка',
                 'Computer science rating',
                 'Weight']].values.reshape(-1, 7))
```

```
pd.crosstab(df_test_cut['Predict'], df_test_cut['Sex_мужской'])
```

Sex_мужской	0	1
Predict		
0	46	1
1	1	29

Решающие деревья

```
df_cut = df[['Growth', 'Weight', 'Sex', 'Hair length', 'Children number']]
df_cut = df_cut.dropna()
```

```
sns.pairplot(df_cut, hue='Sex')
```

```
<seaborn.axisgrid.PairGrid at 0x7f9ac2ab1ad0>
```

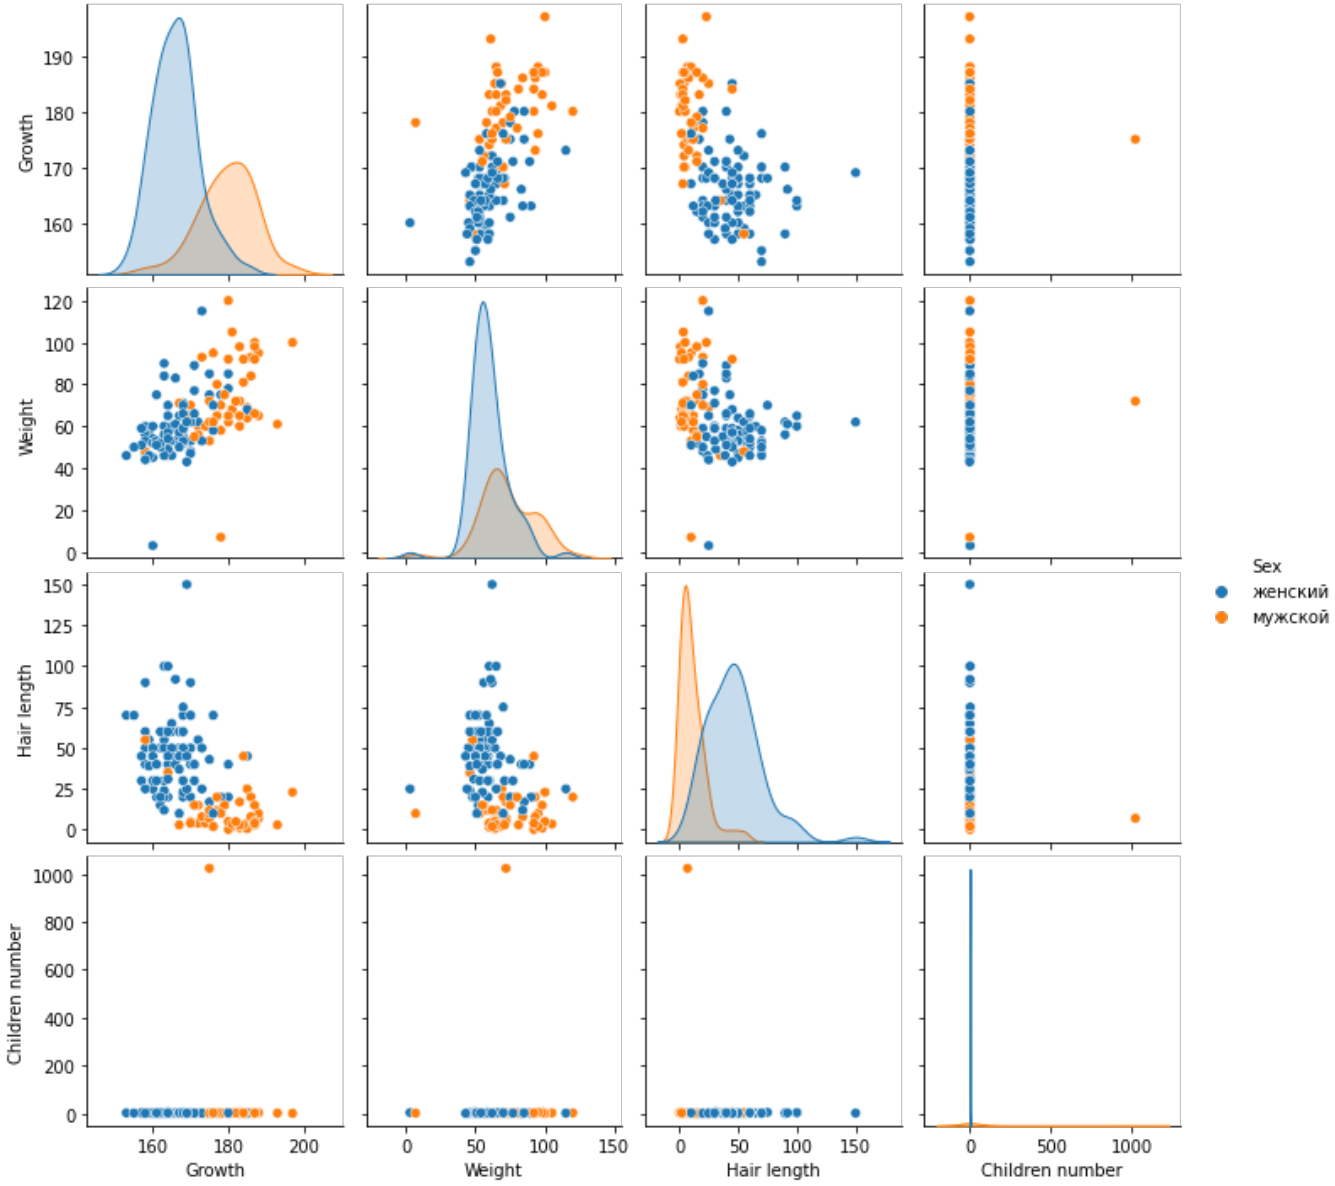


```
model = tree.DecisionTreeClassifier()
```

```
model.fit(df_cut[['Growth', 'Weight', 'Hair length', 'Children number']].values.
          y=df_cut['Sex'].values)
```

```
DecisionTreeClassifier()
```

```
dot_data = tree.export_graphviz(model, out_file=None,
                                feature_names=['Growth', 'Weight', 'Hair length'
                                class_names=['f', 'm'],
                                filled=True, rounded=True,
                                special_characters=True)
graph = graphviz.Source(dot_data)
graph
```

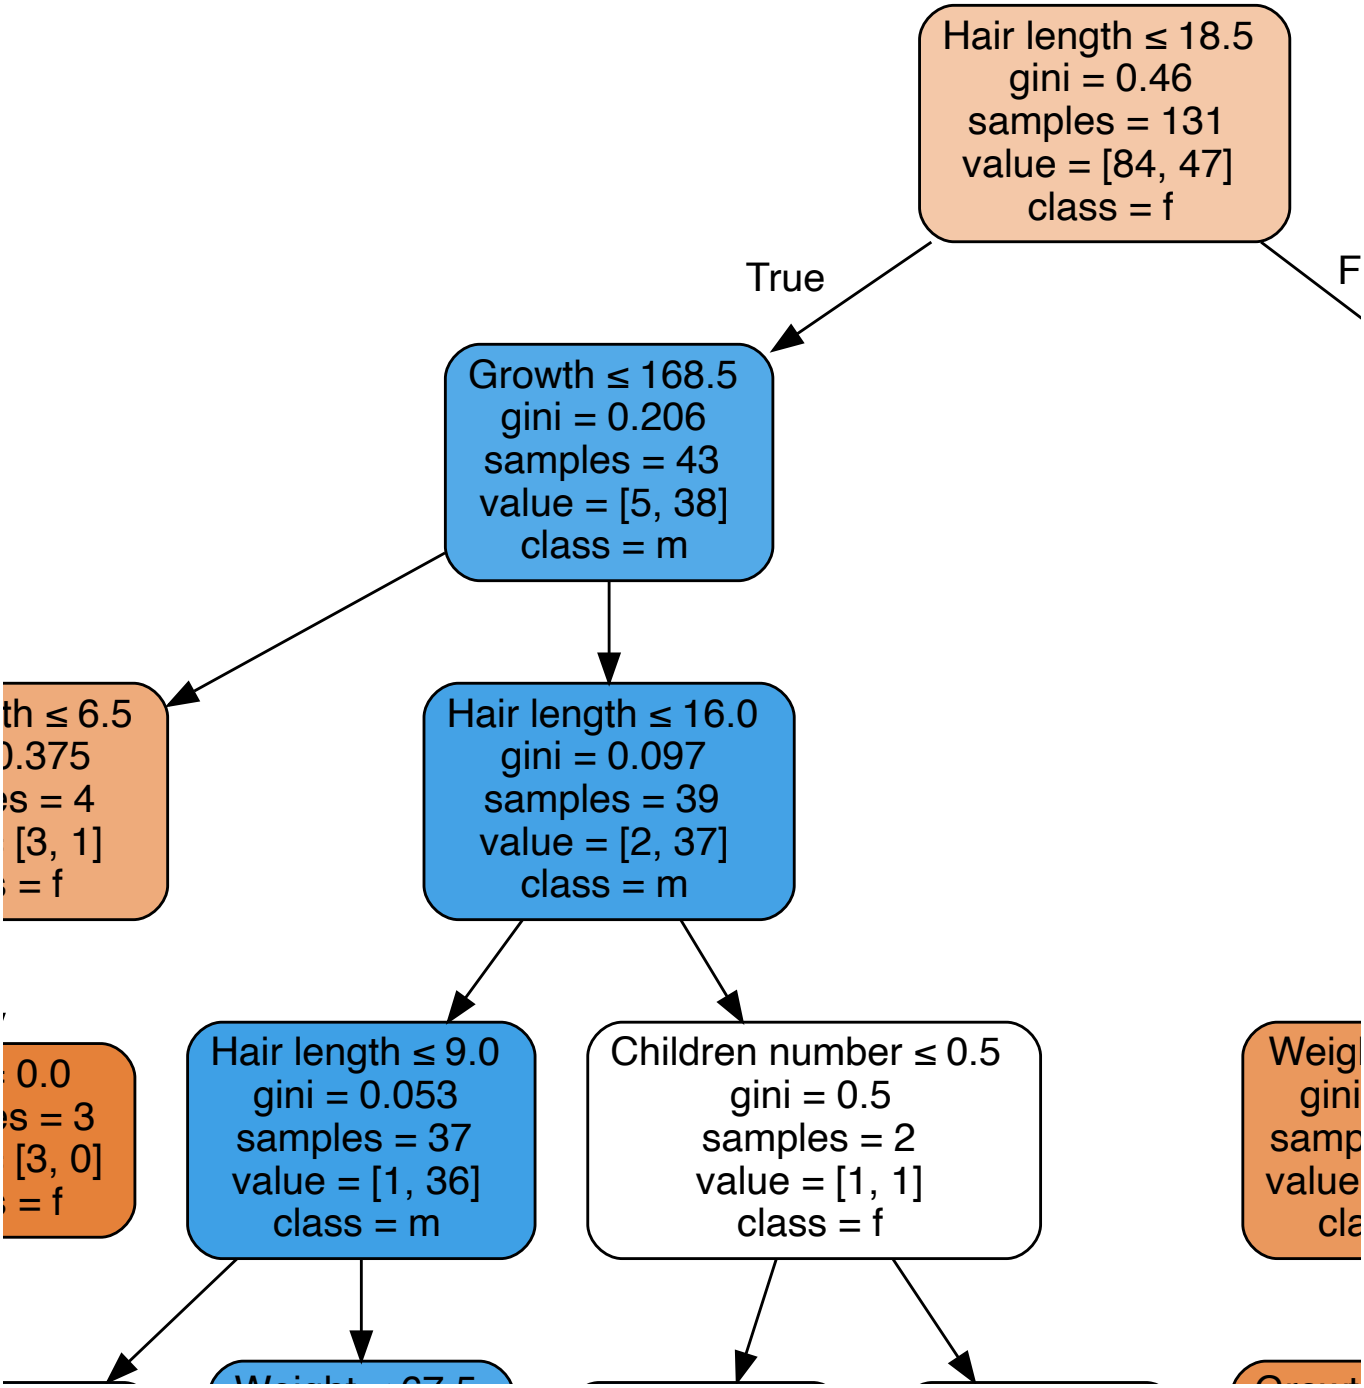

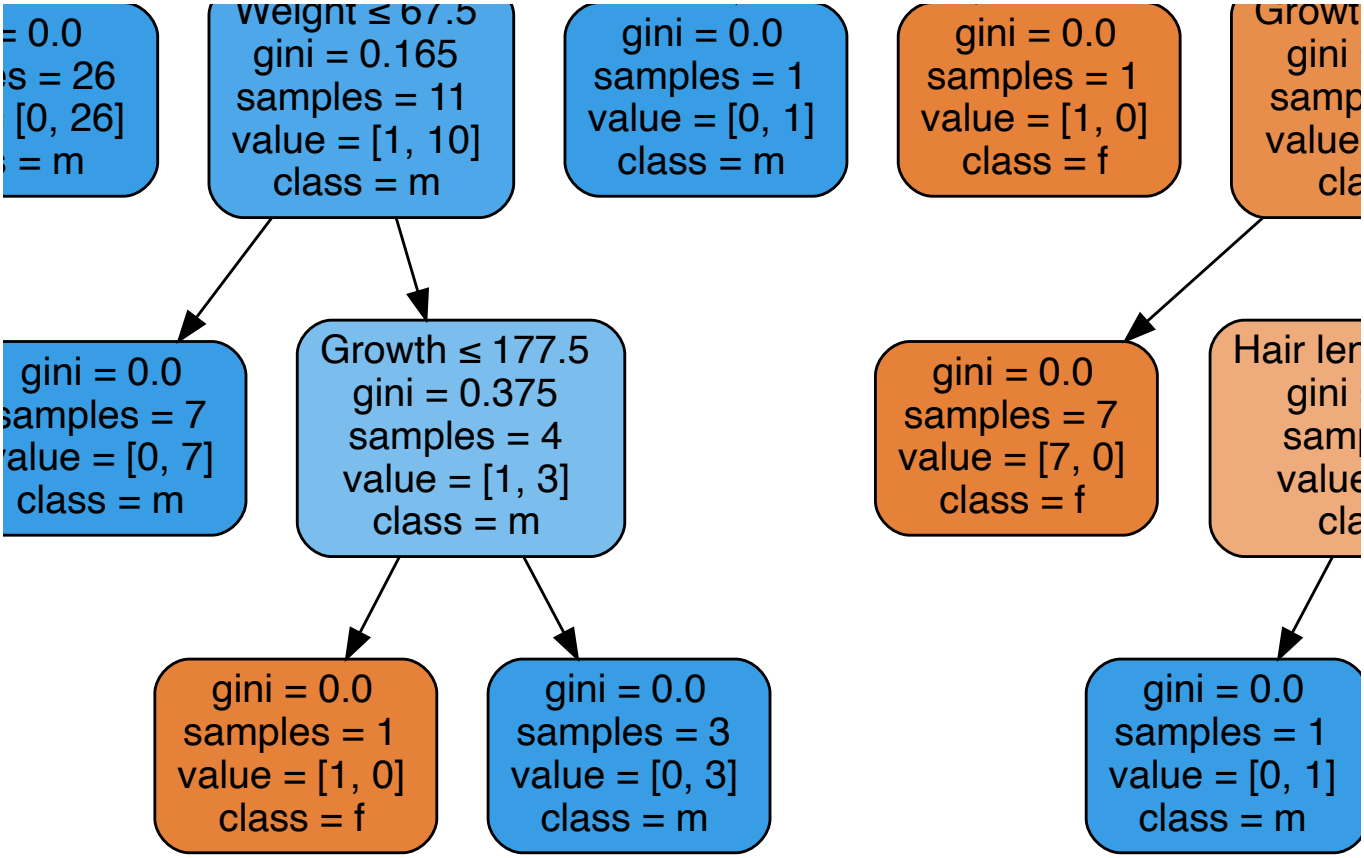


```
df_test_cut = df_test[['Growth', 'Weight', 'Sex', 'Hair length',
                       'Children number']]
df_test_cut = df_test_cut.dropna()
```

Большой плюс - для деревьев не нужно нормировать данные

```
df_test_cut['Predicted'] = model.predict(df_test_cut[['Growth', 'Weight',
                                                      'Hair length', 'Children n
```

```
pd.crosstab(df_test_cut['Predicted'], df_test_cut['Sex'])
```

Sex	женский	мужской
Predicted		
женский	41	1
мужской	1	25

Минусы - громоздкая визуализация. Выйти из ситуации можно с помощью установки параметра max_depth, дерево станет более компактным. Однако точность классификатора может снизиться.

Еще раз про показатели качества классификации

Основных два - precision и recall

precision - доля верных наблюдений в предсказанной группе

recall - доля верных наблюдений среди всех наблюдений данной группы (изначальных, не предсказанных)

Для их подсчета есть функция

```
from sklearn.metrics import precision_recall_fscore_support
```

Здесь важен порядок, первый аргумент - истинные метки, второй - предсказанные. Только в таком случае результаты будут верные

```
precision_recall_fscore_support(df_test_cut['Sex'], df_test_cut['Predicted'])
```

```
    (array([0.97619048, 0.96153846]),
     array([0.97619048, 0.96153846]),
     array([0.97619048, 0.96153846]),
     array([42, 26]))
```

Первая строка - precision для каждого пола

Вторая строка - recall для каждого пола

Третья строка - F1 метрика

4 - количество наблюдений каждого класса

Задача регрессии. Дерево решений

```
df_cut = df[['Growth', 'Weight', 'Hair length', 'Shoe size']]
df_cut = df_cut.dropna()
```

```
sns.pairplot(df_cut)
```

```
<seaborn.axisgrid.PairGrid at 0x7f9ac1ec1d90>
```

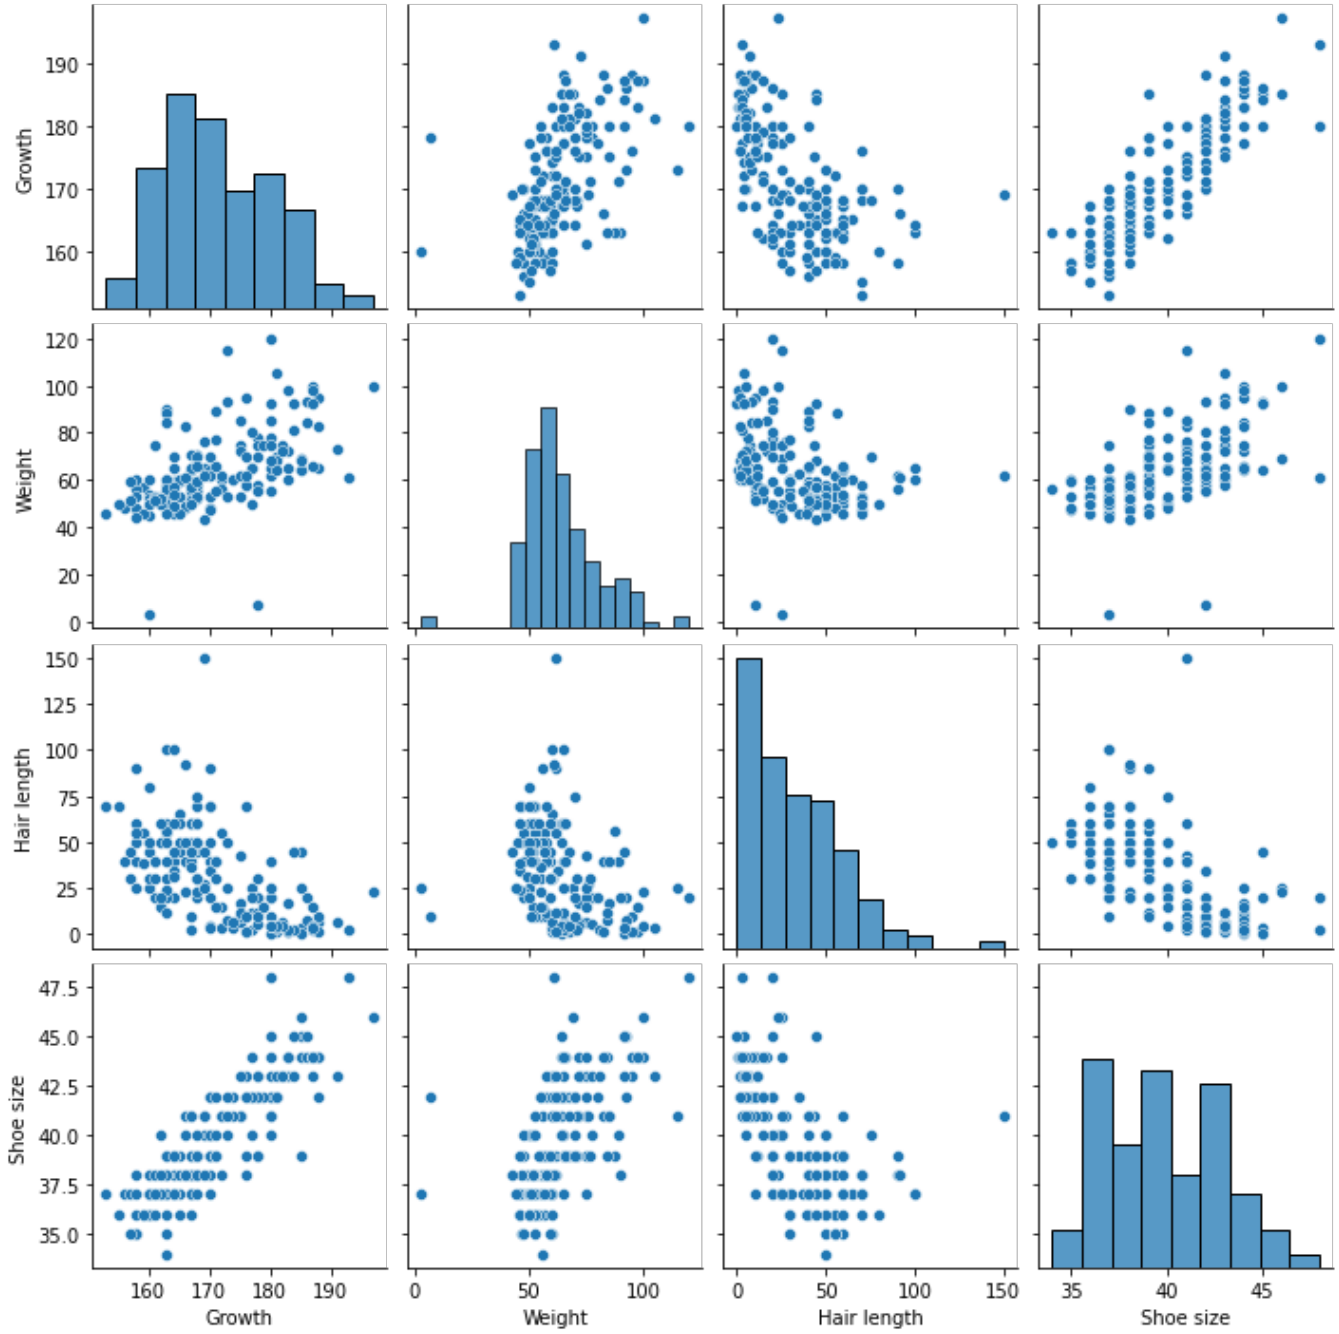

Будем предсказывать рост по всем остальным признакам с помощью DecisionTree**Regressor**

```
model = tree.DecisionTreeRegressor(max_depth=2)
model.fit(df_cut[['Weight', 'Hair length', 'Shoe size']].values.reshape(-1, 3),
          y=df_cut['Growth'].values)
```

```
DecisionTreeRegressor(max_depth=2)
```

```
dot_data = tree.export_graphviz(model, out_file=None,
                                feature_names=['Weight', 'Hair length', 'Shoe si
                                class_names='Growths',
                                filled=True, rounded=True,
                                special_characters=True)
graph = graphviz.Source(dot_data)
graph
```

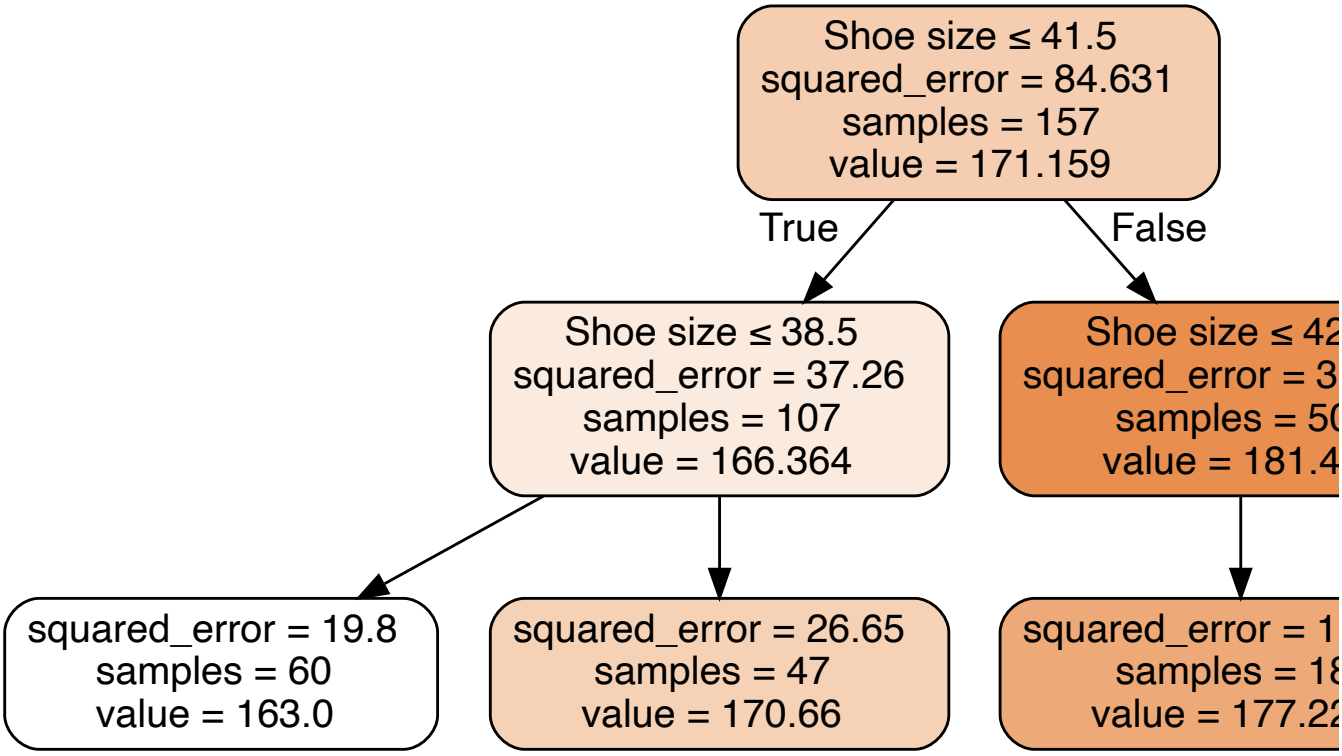


```
df_test_cut = df_cut[['Growth', 'Weight', 'Shoe size', 'Hair length']]
df_test_cut = df_test_cut.dropna()
```

```
df_test_cut['Predicted'] = model.predict(df_test_cut[['Weight', 'Hair length', '
```

В отличие от классификации, здесь для проверки качества используем среднюю абсолютную ошибку

```
mean_absolute_error(df_test_cut['Growth'], df_test_cut['Predicted'])
```

```
3.7618918552649414
```

Для разных значений глубины поиска можно получать разные значения точности. Но не всегда большее значение ведет к возрастанию точности. Здесь можно столкнуться с проблемой переобучения.

Бустинг и ансамбли алгоритмов

С точки зрения статистики, совместное использование (ансамбль) нескольких алгоритмов машинного обучения будет давать большую точность, чем эти алгоритмы по-отдельности

Пример - RandomForest, составленный из различных деревьев

```
df_cut = df[['Growth', 'Weight', 'Sex', 'Hair length', 'Children number']]
df_cut = df_cut.dropna()
```

```
model = RandomForestClassifier(max_depth=2, random_state=0)
model.fit(df_cut[['Growth', 'Weight', 'Hair length', 'Children number']].values.
          y=df_cut['Sex'].values)
```

```
RandomForestClassifier(max_depth=2, random_state=0)
```

```
df_test_cut = df_test[['Growth', 'Weight', 'Sex', 'Hair length', 'Children numbe
df_test_cut = df_test_cut.dropna()
```

```
df_test_cut['Predicted'] = model.predict(df_test_cut[['Growth', 'Weight','Hair l
```

```
pd.crosstab(df_test_cut['Sex'], df_test_cut['Predicted'])
```

Predicted	женский	мужской
Sex		
женский	42	0
мужской	1	25

Градиентный бустинг

```
from sklearn.ensemble import GradientBoostingClassifier
```

```
model = GradientBoostingClassifier(random_state=0)
model.fit(df_cut[['Growth', 'Weight', 'Hair length', 'Children number']].values.
          y=df_cut['Sex'].values)
```

```
GradientBoostingClassifier(random_state=0)
```

```
df_test_cut = df_test[['Growth', 'Weight', 'Sex', 'Children number',
                       'Hair length']]
df_test_cut = df_test_cut.dropna()
```

```
df_test_cut['Predicted'] = model.predict(df_test_cut[['Growth',
                                                      'Weight',
                                                      'Hair length',
                                                      'Children number']].values
```

```
pd.crosstab(df_test_cut['Sex'], df_test_cut['Predicted'])
```

Predicted	женский	мужской
Sex		
женский	42	0
мужской	1	25

```
precision_recall_fscore_support(df_test_cut['Sex'], df_test_cut['Predicted'])
```

```
(array([0.97674419, 1.        ]),
 array([1.        , 0.96153846]),
 array([0.98823529, 0.98039216]),
 array([42, 26]))
```

В данном месте повторяется раздел "Вероятностные алгоритмы"

Повторим итог

```
model = RandomForestClassifier(max_depth=2, random_state=0)
model.fit(df_cut[['Growth', 'Weight', 'Hair length', 'Children number']].values.
          y=df_cut['Sex'])
```

```
RandomForestClassifier(max_depth=2, random_state=0)
```

```
df_test_cut = df_test[['Growth', 'Weight', 'Sex', 'Children number',
                       'Hair length']]
df_test_cut = df_test_cut.dropna()
```

```
result = model.predict_proba(df_test_cut[['Growth', 'Weight',
                                                    'Hair length',
                                                    'Children number']].
```

```
df_test_cut['pr class 0'] = result[:, 0]
df_test_cut['pr class 1'] = result[:, 1]
df_test_cut.head()
```

	Growth	Weight	Sex	Children number	Hair length	pr class 0	pr class 1
0	180.0	78.0	мужской	2.0	1.2	0.111984	0.888016
1	167.0	50.0	женский	2.0	30.0	0.960954	0.039046
3	156.0	47.0	женский	2.0	20.0	0.930384	0.069616
5	150.0	40.0	женский	2.0	30.0	0.954804	0.045196
7	183.0	80.0	мужской	0.0	2.0	0.072297	0.927703

```
df_test_cut[(df_test_cut['Sex'] == 'мужской') & (df_test_cut['pr class 1'] > 0.9
```

	Growth	Weight	Sex	Children number	Hair length	pr class 0	pr class 1
7	183.0	80.0	мужской	0.0	2.0	0.072297	0.927703
23	194.0	97.0	мужской	0.0	5.0	0.057225	0.942775
25	185.0	72.3	мужской	100.0	4.0	0.098636	0.901364
27	185.0	93.0	мужской	2.0	10.0	0.094359	0.905641
28	193.0	105.0	мужской	2.0	11.0	0.094359	0.905641
33	196.0	97.0	мужской	2.0	15.0	0.096930	0.903070
45	185.0	65.0	мужской	2.0	4.0	0.076419	0.923581
48	185.0	85.0	мужской	2.0	4.0	0.079070	0.920930
60	191.0	85.0	мужской	2.0	3.0	0.079070	0.920930
82	182.0	92.0	мужской	0.0	4.0	0.057225	0.942775
93	183.0	68.0	мужской	0.0	8.0	0.076349	0.923651
97	188.0	73.0	мужской	2.0	3.0	0.079070	0.920930

Платные продукты Colab - Отменить подписку